Fachhochschule Nordwestschweiz
Hochschule für Technik und Umwelt

Athletes Network
Soziale Netzwerkanalyse im Schwimmsport

Projektarbeit im Modul Soziale Netzwerke

[Abgabedatum ergänzen]

Projektteam	Zéphyr Kesseler, Damian Szedalik
Modul	Soziale Netzwerke
Studiengang	Data Science & AI
Hochschule	Fachhochschule Nordwestschweiz

Inhaltsverzeichnis

1 Einleitung **1**

1.1 Ausgangslage und Ziel 1

1.2 Fragestellungen 1

2 Datenbeschaffung und explorative Datenanalyse **1**

2.1 Datenquelle und Erhebung 1

2.2 Bereinigung und Datenqualität 2

2.3 Erkenntnisse und Grenzen 2

3 Modellierung **3**

3.1 Athleten und Veranstaltungstage 3

3.2 Gewichtete Athletenprojektion 4

3.3 Disziplinennetzwerk und Modellgrenzen 5

4 Reduktion des Netzwerks **7**

4.1 Filtern nach Kantengewicht 7

4.2 Local View nach Geschlecht 7

4.3 Global View nach Profilnation 8

4.4 Contextual View für die Schweiz 10

4.5 Ego-Netzwerk von Michael Phelps 11

5 Communities **12**

5.1 Cliquen und k-Core 12

5.2 Louvain und Label Propagation 12

5.3 Communities und Nationen 14

5.4 Communities im Nationennetz 14

6 Wichtigkeit von Knoten & Knotengruppen **14**

6.1 Zentrale Athleten 14

6.2 Leistung und Zentralität 16

6.3 Nationalteams und Generationen 17

7 Zusammenhalt des Netzwerks **19**

7.1 Kennzahlen und Nullmodell 19

7.2 Robustheit 19

7.3 Generationen im Vergleich 20

8 Assortativität **21**

8.1 Gesamtnetz 21

8.2 Elite-Club oder Altersklassen 22

9 Link Prediction **23**

9.1 Versuchsaufbau 23

9.2 Ergebnisse 24

10 Fazit und Ausblick **26**

10.1 Beantwortung der Fragestellungen 26

10.2 Grenzen, Ausblick und Reflexion 27

Literaturverzeichnis **28**

A Übersicht über Code und Daten **29**

B Hilfsmittelverzeichnis **29**

1 Einleitung

1.1 Ausgangslage und Ziel

Schwimmer messen sich an nationalen Meisterschaften, an internationalen Wettkampfserien sowie an Welt- und Europameisterschaften. Ranglisten zeigen, wer wie schnell schwimmt. Sie zeigen aber nicht, wer wem an Wettkämpfen begegnet und wie sich daraus ein Netz des Schwimmsports bildet. Genau diesen Blick ermöglicht die soziale Netzwerkanalyse. Wir verbinden Athleten, die am selben Veranstaltungstag eine Bestleistung erzielten, und untersuchen die Struktur dieses Netzes.

Grundlage sind die TOP100-Listen von swimrankings.net mit den persönlichen Bestleistungen von über 13 000 Athleten aus 182 Nationen. Erhoben wurden sie mit einem Scraper aus einem früheren Projekt (Kapitel 2). Ziel ist zu verstehen, wie national oder international der Schwimmsport vernetzt ist, welche Athleten und Veranstaltungen das Netz prägen und ob sich künftige Begegnungen vorhersagen lassen.

1.2 Fragestellungen

Daraus leiten wir fünf Fragen ab.

1. Wie stark ist das Netz national geprägt, und welche Gruppen bilden sich (Kapitel 4 und 5)?
2. Welche Athleten und Nationalteams sind zentral, und sind stärkere Schwimmer zentraler (Kapitel 6)?
3. Was hält das Netz zusammen, einzelne Athleten oder grosse Veranstaltungen (Kapitel 7)?
4. Mit wem verbinden sich Athleten bevorzugt (Kapitel 8)?
5. Lassen sich künftige Begegnungen aus der Netzwerkstruktur vorhersagen (Kapitel 9)?

Die Untersuchung beschränkt sich auf die gespeicherten Bestleistungen der TOP100-Listen mit Stand 2025. Eine Kante bedeutet, dass zwei Athleten am selben Veranstaltungstag eine ihrer Karrierebestzeiten erzielten. Sie belegt weder eine persönliche Bekanntschaft noch ein direktes Rennen gegeneinander. Die Netze fassen alle Jahre zusammen, nur die Link Prediction trennt zwei Zeiträume. Die verwendeten Verfahren und Masse folgen, wo nicht anders angegeben, dem Skript von Henninger (2024). Kapitel 2 und 3 beschreiben Daten und Modellierung, die Kapitel 4 bis 9 die Analysen. Kapitel 10 beantwortet die Fragen und gibt einen Ausblick.

2 Datenbeschaffung und explorative Datenanalyse

2.1 Datenquelle und Erhebung

Der verwendete Scraper entstand 2025 im Rahmen eines anderen Projekts. Mit Python und Selenium wurden Mitte 2025 auf swimrankings.net (2025) die TOP100 Listen mit bis zu 100 Männern und 100 Frauen je Land sowie deren persönliche Bestleistungen erfasst. Die vorliegende Arbeit verwendet diese gespeicherten Rohdaten weiter. Eine Zeile entspricht einem Bestleistungseintrag und verbindet Athletenmerkmale wie Jahrgang, Geschlecht, Nation und Verein mit Disziplin, Beckenlänge, Zeit, Punkten sowie Datum, Ort und Wettkampfname. Pro Athlet ist je Disziplin und Beckenlänge nur die schnellste Zeit der Karriere gespeichert. Verbessert ein Athlet diese Zeit, ersetzt der neue Eintrag den früheren.

Das Land der ausgewählten Liste (Listenland) kann von der Nation im Athletenprofil (Profilnation) abweichen. Beispielsweise erscheinen Athleten mit spanischer Profilnation auch auf portugiesischen Listen. Beim Zusammenführen aller Länderlisten können deshalb mehr als 200 Personen derselben Profilnation im Datensatz enthalten sein.

Ein ergänzendes Skript sollte 126 vermutete Erhebungsausfälle nachladen. Bei diesen Profilen fehlten sowohl Bestleistungen als auch Detailangaben. Der im EDA Notebook dokumentierte Versuch scheiterte an Cloudflare Prüfungen, obwohl das Skript mit einer manuellen Prüfung im Browser durchgeführt wurde. Es wurden dadurch keine zusätzlichen Daten gewonnen.

2.2 Bereinigung und Datenqualität

Entfernt wurden 1 688 Zeilen ohne Bestleistungen von 1 687 Athleten, 134 exakte Duplikate und der unplausible Quellenwert `55:55.55` über 200 m Brust. Fehlende Bestleistungen gelten dabei nicht grundsätzlich als Erhebungsfehler. Zeiten wurden in Sekunden umgerechnet und Datentypen vereinheitlicht. Leerzeichen in Wettkampfnamen, Orten und Beckenlängen wurden bereinigt, fehlende Angaben einschliesslich `UNKNOWN` einheitlich als `Unknown` gespeichert. Die kombinierte Profilangabe wurde in Nation und Verein aufgeteilt. Listenland und Profilnation bleiben erhalten, da sie bei 215 Athleten voneinander abweichen.

Quellenstichproben und Plausibilitätsprüfungen ergänzten die Bereinigung. Die auffälligen ungefähren Alterswerte von 6 und 66 Jahren wurden bestätigt und beibehalten. Der Parquet Export wurde erneut eingelesen und auf Übereinstimmung mit der bereinigten Tabelle geprüft. Tabelle 2.1 zeigt den resultierenden Datenumfang. Die einzelnen Prüfungen sind in Notebooks/01_eda.ipynb dokumentiert.

Tabelle 2.1: Datenumfang vor und nach der Bereinigung. Eigene Auswertung.

Datenstand	Zeilen	Athleten
Rohdaten	286 996	14 849
Bereinigt	285 173	13 162

2.3 Erkenntnisse und Grenzen

Für die Auswertung nach Nation zählt jede Athletenkennung einmal und wird der Profilnation zugeordnet. Die 13 162 Athleten verteilen sich auf 182 Profilnationen. Die Abdeckung reicht von einer bis zu 218 Personen pro Nation, der Median beträgt nur 28. Männer machen 55,7 % und Frauen 44,3 % aus. Die 126 vermuteten Erhebungsausfälle betreffen 122 Frauen und 4 Männer. Länderanalysen und Geschlechtervergleiche können dadurch verzerrt sein. Bei den bekannten Geburtsjahrgängen liegt der Median bei 1997, die mittleren 50 % liegen zwischen 1989 und 2002.

Pro Athlet sind im Median 19 Bestleistungseinträge gespeichert, die mittleren 50 % umfassen 9 bis 34 Einträge. Einzelne Personen sind damit deutlich umfangreicher dokumentiert als andere. Die Leistungen verteilen sich mit 52,0 % auf die Langbahn (50 m) und mit 48,0 % auf die Kurzbahn (25 m). Neben vollständigen Strecken sind auch Zwischenzeiten mit dem Zusatz `Lap` enthalten.

Die datierten Einträge reichen vom 17. Oktober 1964 bis zum 8. April 2025. Davon stammen 94,7 % aus den Jahren ab 2005. Abbildung 2.1 zeigt den lokalen Anstieg 2009 und den Einbruch 2020. Ursachen lassen sich daraus allein nicht ableiten (wir vermuten jedoch den Einfluss vom Supersuit (2009) und dem Einfluss der Pandemie (2020)). Das Jahr 2025 ist nur teilweise erfasst und daher nicht direkt mit vollständigen Jahren vergleichbar. Für die weitere Modellierung bleiben alle Jahre erhalten.

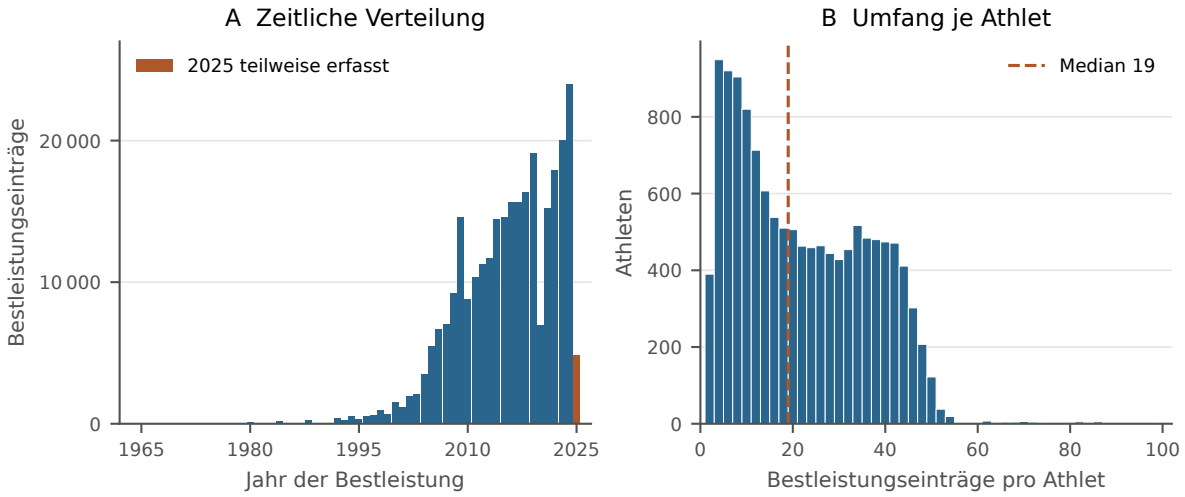


Abbildung 2.1: Zeitliche Verteilung und Umfang der gespeicherten Bestleistungen. Links fehlt ein Eintrag ohne Datum. Rechts zählt jeder Athlet einmal. Eigene Auswertung.

Bei 5 115 Athleten (38,9 %) fehlen Vereinsangaben. Auch die Punkte sind nicht vollständig: Von 53 577 Einträgen ohne Punkte entfallen 53 019 auf `Lap` und 558 auf seltene Kombinationen aus Disziplin und Beckenlänge. Diese Lücken bestehen bereits in der Quelle und häufen sich somit bei bestimmten Leistungsarten.

Die Auswahl über TOP100 Listen und persönliche Bestleistungen bildet weder den gesamten Schwimmsport noch vollständige Wettkampfbiografien ab. Die Häufigkeiten beschreiben gespeicherte Bestleistungen und erlauben keine direkten Aussagen zur Anzahl aller Wettkampfteilnahmen. Gekürzte und wiederholte Wettkampfnamen bleiben erhalten, sind für sich allein aber keine eindeutigen Veranstaltungskennungen. Die Datenbasis bleibt auf dem Erhebungsstand von 2025.

3 Modellierung

Wir modellieren gemeinsame Veranstaltungstage von Athleten und gemeinsame Disziplinen ihrer Bestleistungen. Beide Modelle verwenden alle Jahre und Geschlechter. Die Beziehungen sind wechselseitig, deshalb sind die Netzwerke ungerichtet. Sie fassen die Beobachtungen statisch zusammen.

3.1 Athleten und Veranstaltungstage

Im bipartiten Hauptmodell (Two Mode) verbindet eine Kante einen Athleten mit einem Veranstaltungstag, an dem mindestens eine seiner Bestleistungen gespeichert ist. Wettkampfname, Ort, Datum und Beckenlänge bestimmen den Tag. Mehrtägige Wettkämpfe werden tageweise betrachtet, Kurzbahn und Langbahn bleiben getrennt.

Jede Athletenkennung bildet einen Knoten. Mehrere Leistungen am selben Veranstaltungstag und Einträge aus mehreren Länderlisten erzeugen keine zusätzlichen Kanten. Zwischenzeiten mit `Lap` bleiben als Beleg für einen Veranstaltungstag verwendbar. Für 854 Einträge fehlen notwendige Veranstaltungsangaben. Sie werden nur von dieser Zuordnung ausgeschlossen. Sechs Athleten haben damit keinen zuordenbaren Tag und entfallen im Hauptmodell. Ein Veranstaltungstag erscheint für einen Athleten also nur, wenn er dort mindestens eine seiner Karrierebestzeiten

erzielte. Wenn wir im Folgenden von einer Begegnung sprechen oder davon, dass sich Athleten treffen, meinen wir einen solchen gemeinsamen Bestleistungstag. Viele tatsächliche Begegnungen an Wettkämpfen sind deshalb nicht erfasst.

3.2 Gewichtete Athletenprojektion

Die gewichtete Transformation gemäss Henninger (2024, S. 38) überführt das bipartite Modell in ein Netzwerk mit nur einem Knotentyp (One Mode). Zwei Athleten werden verbunden, sobald sie einen Veranstaltungstag teilen. Das Kantengewicht zählt ihre verschiedenen gemeinsamen Tage. Für die Tagesmengen $T(u)$ und $T(v)$ gilt somit $w_{uv} = |T(u) \cap T(v)|$. Diese Gewichtung erhält die Häufigkeit gemeinsamer Veranstaltungskontexte und ist unmittelbar interpretierbar. Abbildung 3.1 veranschaulicht die Transformation an zwei Tagen in Sarajevo.

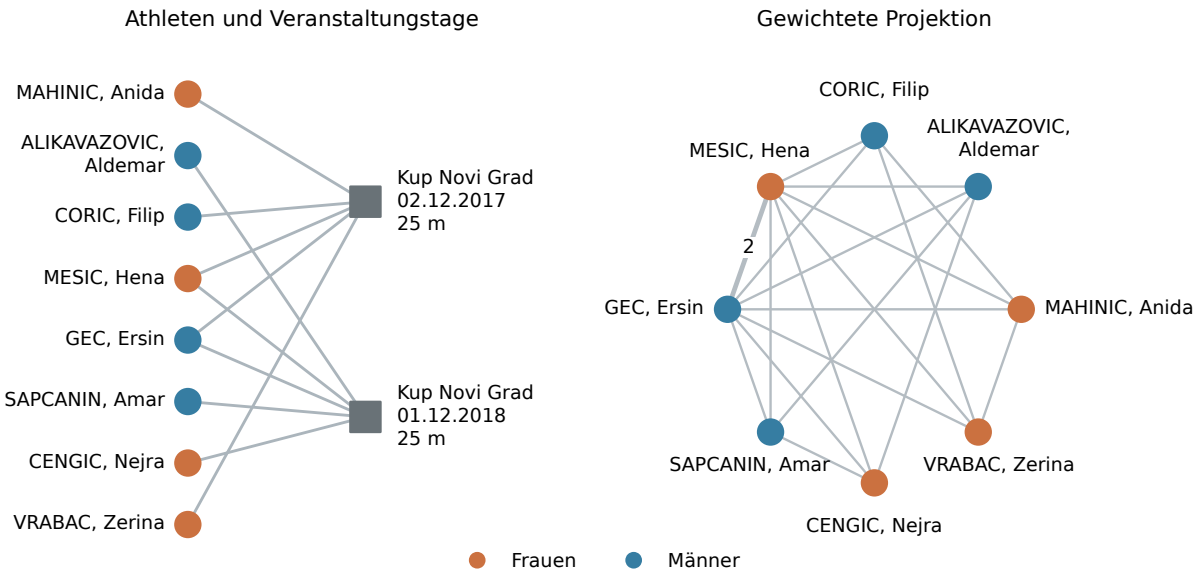


Abbildung 3.1: Bipartites Modell und gewichtete Projektion für zwei Veranstaltungstage des Kup Novi Grad mit acht Athleten. Die Gewichte zählen ausschliesslich gemeinsame Tage im gezeigten Ausschnitt. Unbeschriftete Kanten haben Gewicht 1. Eigene Darstellung.

Die vollständige Projektion wird aus allen Veranstaltungstagen berechnet. Auch die 20 Athleten ohne gemeinsame Tage mit anderen Personen bleiben als isolierte Knoten enthalten. Tabelle 3.1 zeigt den Umfang der drei gespeicherten Darstellungen.

Tabelle 3.1: Umfang der vollständigen Netzwerke. Eigene Auswertung.

Netzwerk	Knoten	Kanten	Isolierte Knoten
Bipartites Hauptmodell	76 102	238 942	0
Athletenprojektion	13 156	1 231 245	20
Disziplinennetzwerk	78	2 265	0

Als Athletenattribute bleiben Name, Geschlecht, Profilnation, Geburtsjahr und Verein erhalten, soweit sie vorliegen. Veranstaltungsknoten tragen die vier Angaben ihrer Zuordnung.

Die vollständige Darstellung im Notebook ist wegen der vielen überlagerten Knoten schwer lesbar. Für Abbildung 3.2 wurde das Netzwerk deshalb in Gephi angeordnet und anschliessend für die

Anzeige gefiltert. Es bleiben 135 353 sichtbare Kanten. Die räumlichen Abstände sind vom Layout abhängig und keine exakten Masse für die Stärke einer Beziehung. Die Abbildung dient dem Überblick.

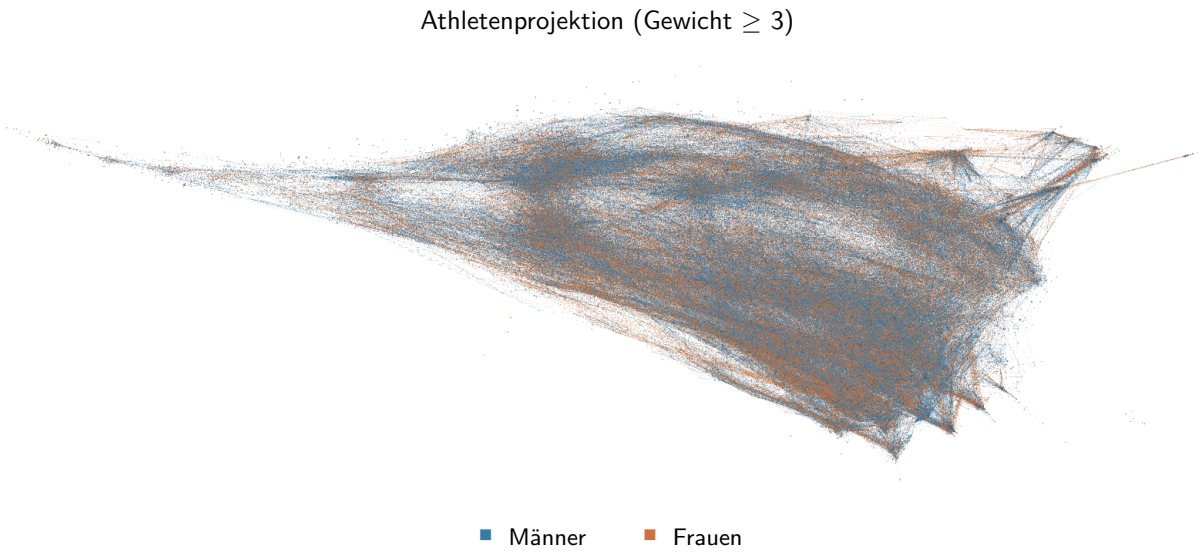


Abbildung 3.2: Gewichtete Athletenprojektion mit ForceAtlas 2. Die Anordnung wurde auf dem vollständigen Netzwerk berechnet und vor dem Filtern gestoppt. Sichtbar sind nur Kanten mit mindestens drei gemeinsamen Veranstaltungstagen. Männer sind blau, Frauen orange. Eigene Darstellung in Gephi.

3.3 Disziplinennetzwerk und Modellgrenzen

Im zweiten Modell bildet jede Kombination aus Strecke, Schwimmstil und Beckenlänge einen Knoten. Beispielsweise sind 100 m Freistil auf Kurzbahn und Langbahn verschiedene Knoten. Aus der Zuordnung von Athleten zu diesen Kombinationen entsteht eine gewichtete Projektion auf die Disziplinen. Das Kantengewicht zählt die verschiedenen Athleten mit Bestleistungen in beiden Kombinationen. Dafür ist keine gemeinsame Veranstaltung nötig. Jeder Athlet zählt je Kombination einmal, Zwischenzeiten mit `Lap` werden ausgeschlossen.

Alle 78 Kombinationen bleiben enthalten, davon sind 29 bei weniger als zehn Athleten belegt. Abbildung 3.3 zeigt diese Unterschiede in der Abdeckung. Ein konkretes Beispiel für die Gewichtung sind 100 m und 200 m Freistil auf Langbahn: 8 503 Athleten sind in beiden Disziplinen erfasst, entsprechend beträgt ihr Kantengewicht 8 503.

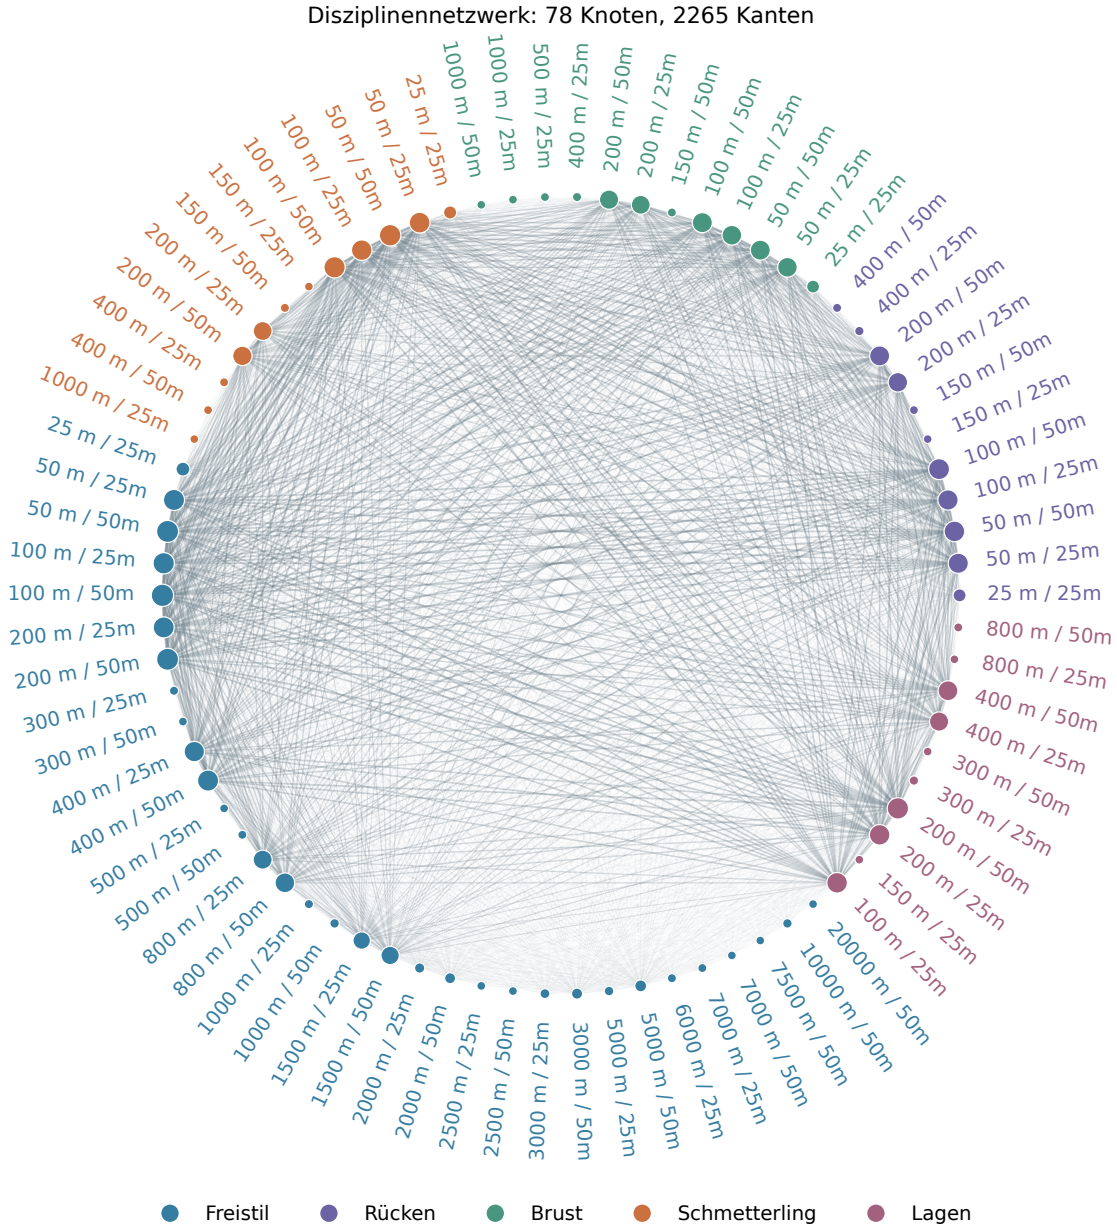


Abbildung 3.3: Disziplinennetzwerk mit allen 78 Kombinationen. Die Farben kennzeichnen Schwimmstile, die Beschriftungen Strecke und Beckenlänge. Grössere Knoten stehen für mehr Athleten, kräftigere Kanten für mehr gemeinsame Athleten. Die Reihenfolge am Kreis folgt Schwimmstil und Strecke. Eigene Darstellung.

Aufbau und Prüfungen sind in Notebooks/02_modellierung.ipynb dokumentiert. Geprüft wurden unter anderem eindeutige Zuordnungen, fehlende Selbstkanten, konkrete Gewichte und deren Gesamtsumme. Die Netzwerke und Zuordnungstabellen werden als GEXF und Parquet gespeichert.

Die Modelle beschreiben Zusammenhänge in den ausgewählten Bestleistungsdaten. Gemeinsame Tage belegen weder persönliche Bekanntschaft noch direkte Wettkämpfe. Abweichende Namen können Verbindungen verdecken, identische Kürzungen Veranstaltungen fälschlich zusammenfassen. Jeder Veranstaltungstag verbindet in der Projektion alle dort erfassten Athleten. Ein Teil der Vernetzung entsteht somit durch die Modellkonstruktion. Disziplinengewichte hängen zudem von der Häufigkeit der Disziplinen ab.

4 Reduktion des Netzwerks

Die Athletenprojektion ist mit über 1,2 Millionen Kanten für viele Verfahren und Darstellungen zu gross. Wir reduzieren sie zuerst über das Kantengewicht. Anschliessend betrachten wir das Ergebnis getrennt nach Geschlecht (Local View), zusammengefasst nach Profilnation (Global View), kombiniert am Beispiel der Schweiz (Contextual View) und aus der Sicht eines einzelnen Athleten (Ego-Netzwerk).

4.1 Filtern nach Kantengewicht

Die Gewichte sind stark rechtsschief (Abbildung 4.1A). 71,0 % der Kanten beruhen auf nur einem gemeinsamen Veranstaltungstag. Der Median beträgt 1, das 99. Perzentil 6 und das Maximum 25. Abbildung 4.1B zeigt die Wirkung verschiedener Mindestgewichte. Alle 13 156 Athleten bleiben dabei als Knoten erhalten.

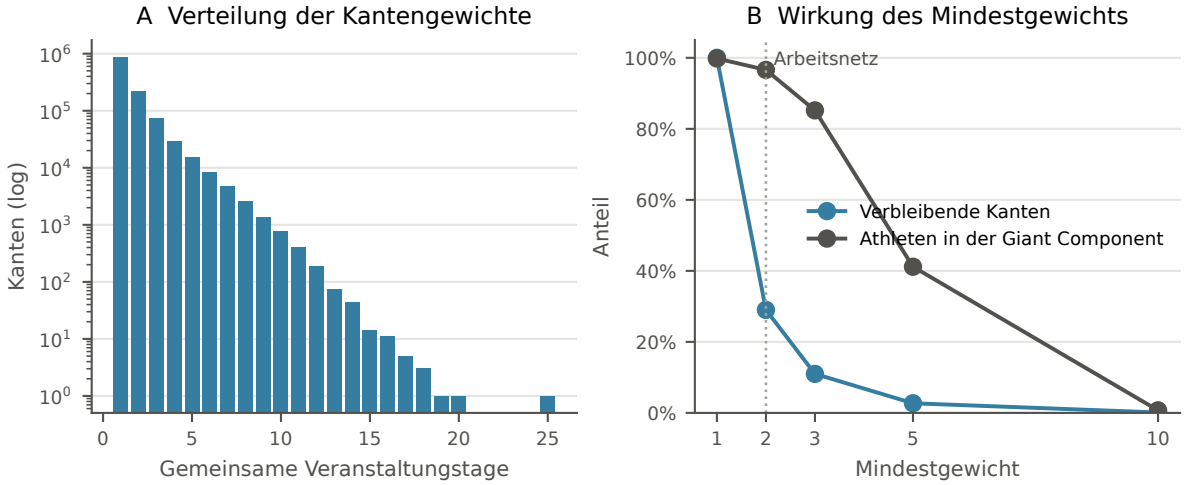


Abbildung 4.1: Kantengewichte der Athletenprojektion. A: Anzahl Kanten je Zahl gemeinsamer Tage (logarithmische Achse). B: Anteil verbleibender Kanten (blau) und Anteil der Athleten in der Giant Component (grau) je Mindestgewicht, gepunktet das Arbeitsnetz. Eigene Auswertung.

Als Arbeitsnetz verwenden wir ein Mindestgewicht von zwei gemeinsamen Tagen. Es entfernt 71 % der Kanten, die Giant Component, also die grösste zusammenhängende Komponente, umfasst aber weiterhin 96,6 % der Athleten. Die Zahl isolierter Athleten steigt dabei von 20 auf 413. Ab Gewicht 5 liegt mehr als die Hälfte der Athleten ausserhalb der Giant Component. Gewicht 3 dient nur der Darstellung in Abbildung 3.2. Die Giant Component des Arbeitsnetzes mit 12 709 Athleten verwenden wir nur für Verfahren, die einen zusammenhängenden Graphen voraussetzen. Der Filter bevorzugt Athleten, deren Bestleistungen wiederholt an denselben Veranstaltungen erfasst sind. Spätere Ergebnisse hängen deshalb auch vom gewählten Schwellenwert ab.

4.2 Local View nach Geschlecht

Tabelle 4.1 vergleicht die Teilnetze der Frauen und Männer im Arbeitsnetz. Beide sind ähnlich dicht und fast vollständig zusammenhängend. Der höhere mittlere Grad der Männer erklärt sich bei ähnlicher Density weitgehend durch die grössere Zahl erfasster Männer. 47,2 % aller Kanten verbinden jedoch Frauen und Männer, da die meisten Veranstaltungen beide Geschlechter umfassen. Diese Durchmischung ist auch in Abbildung 3.2 sichtbar.

Ob gleiche Geschlechter dennoch häufiger verbunden sind, prüfen wir mit einem gemischten dyadisch-monadischen Hypothesentest. Die Nullhypothese lautet, dass das Geschlecht keinen Zusammenhang mit den Kanten hat. Teststatistik ist der Anteil der Kanten zwischen Athleten gleichen Geschlechts. Für 10 000 Referenz-Netzwerke wird das Geschlecht zufällig auf die Knoten verteilt, die Netzwerkstruktur bleibt unverändert (QAP). Als Effektgrösse dient die Korrelation r zwischen der Adjazenzmatrix und der Matrix «gleiches Geschlecht», das Signifikanzniveau beträgt $\alpha = 0{,}05$. Beobachtet werden 52,8 % Kanten zwischen gleichen Geschlechtern, erwartet 50,6 %. Keine Permutation erreicht mehr als 51,2 %, der Unterschied ist also signifikant ($p < 0{,}0001$). Mit $r = 0{,}003$ ist der Effekt jedoch vernachlässigbar. Die Signifikanz entsteht vor allem durch die grosse Zahl von Kanten. Getrennte Netzwerke würden die gemischte Struktur zerschneiden. Wir analysieren deshalb weiterhin das gemeinsame Arbeitsnetz und berücksichtigen das Geschlecht als Knotenattribut.

Tabelle 4.1: Teilnetze nach Geschlecht im Arbeitsnetz. Mittlerer Grad: durchschnittliche Zahl Nachbarn. Giant Component: Anteil der Athleten des Teilnetzes in dessen Giant Component. Eigene Auswertung.

Teilnetz	Athleten	Kanten	Density	Mittlerer Grad	Giant Component
Frauen	5 832	71 364	0,0042	24,5	95,3 %
Männer	7 324	117 326	0,0044	32,0	94,9 %

4.3 Global View nach Profilnation

Für die Global View fassen wir alle Athleten einer Profilnation im Arbeitsnetz zu einem Knoten zusammen. Das Kantengewicht zwischen zwei Nationen summiert die gemeinsamen Tage ihrer Athletenpaare. Das Nationennetz umfasst 182 Nationen und 11 165 Kanten. Mit einer Density von 0,68 sind rund zwei Drittel aller Nationenpaare über gemeinsame Veranstaltungen direkt verbunden. Die höchsten Gewichte verbinden die USA mit Kanada, China und Japan sowie Indonesien mit Malaysia. Diese rohen Gewichte wachsen jedoch mit der Grösse der Nationen.

Abbildung 4.2 zeigt deshalb nur die 72 Nationen mit mindestens 50 Athleten und für jede Nation ihre drei stärksten Partner, gemessen pro Athlet der Partnernation. Es bilden sich regionale Gruppen, etwa Skandinavien mit dem Baltikum, Südosteuropa, Süd- und Ostasien sowie Frankreich mit Nordafrika. Die USA liegen zentral.

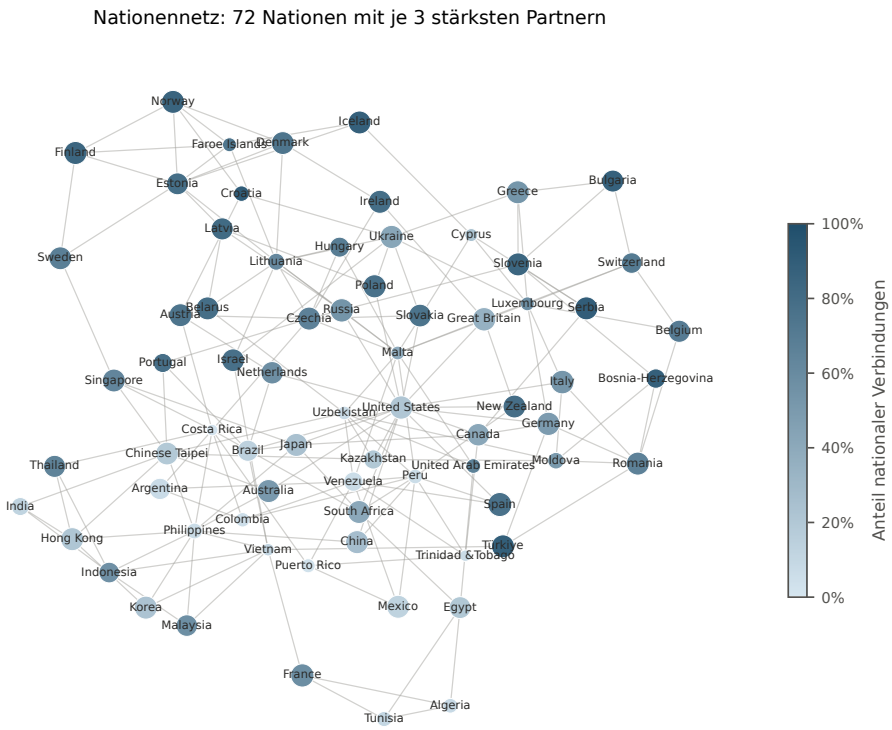


Abbildung 4.2: Nationennetz der 72 Nationen mit mindestens 50 Athleten. Knotengrösse: Zahl der Athleten. Farbe: Anteil der Tage mit Landsleuten. Jede Nation ist mit ihren drei stärksten Partnern verbunden (gemeinsame Tage pro Athlet der Partnernation). Eigene Darstellung.

Trotz dieser internationalen Vernetzung verbinden 43,1 % der Kanten Athleten derselben Nation, zusammen 53,1 % des Gesamtgewichts. Derselbe Hypothesentest wie für das Geschlecht, nun mit permutierter Profilnation, erwartet nur 1,2 %. Keine der 10 000 Permutationen erreicht mehr als 1,3 %. Die nationale Prägung ist damit signifikant ($p < 0{,}0001$) und mit $r = 0{,}25$ deutlich stärker als beim Geschlecht. Das passt zu nationalen Meisterschaften, an denen vor allem Landsleute starten. Abbildung 4.3 vergleicht, welchen Anteil ihrer gemeinsamen Tage die Athleten einer Nation mit Landsleuten teilen. Berücksichtigt sind die 22 Nationen mit mindestens 200 Athleten, die damit ähnlich gross sind. In Serbien, der Türkei, Slowenien und Finnland sind es über 80 %, in den USA, Hongkong, Korea, Japan und China nur 21 bis 27 %. Diese Nationen sind in den Listen vermutlich vor allem mit international startenden Athleten vertreten.

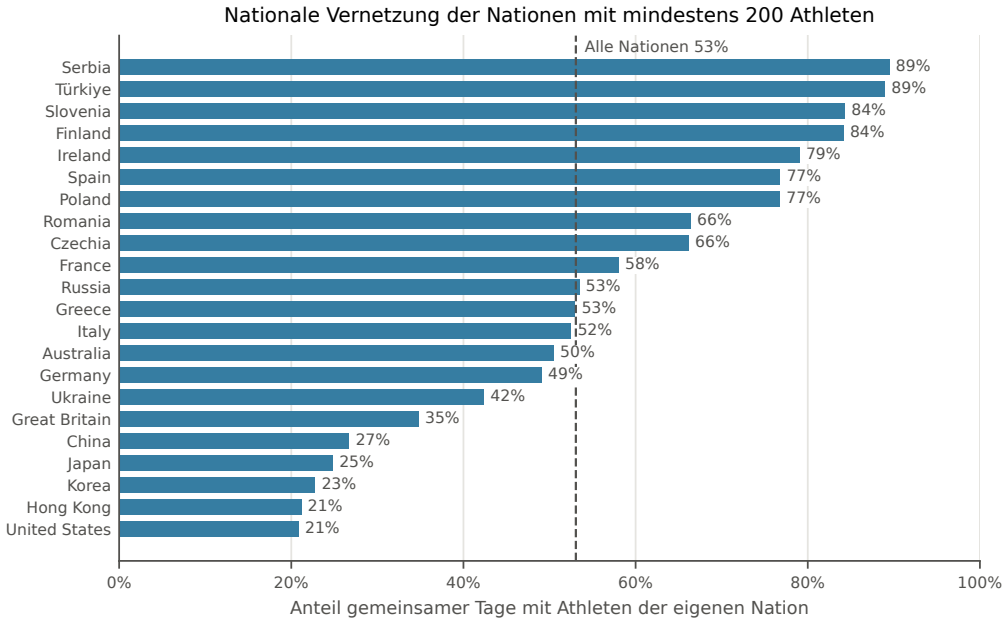


Abbildung 4.3: Anteil der gemeinsamen Tage mit Landsleuten für die 22 Nationen mit mindestens 200 Athleten. Gestrichelt: Anteil über alle Nationen. Eigene Auswertung.

4.4 Contextual View für die Schweiz

Die Contextual View kombiniert beide Sichten. Die 160 Schweizer Athleten bleiben einzelne Knoten (Local View), alle übrigen Athleten des Arbeitsnetzes werden nach Nation zusammengefasst (Global View). Insgesamt teilen die Schweizer 70 % ihrer gemeinsamen Tage mit Landsleuten, im Median pro Athlet sogar 82 %. 152 von ihnen sind mit dem Ausland verbunden, im Median mit Athleten aus sieben Nationen (mittlere 50 % zwischen 4 und 15). Einzelne Athleten der internationalen Spitze verbinden die Schweiz dagegen mit fast hundert Nationen, Noè Ponti mit 97 und Alexandre Haldemann mit 89.

Abbildung 4.4 zeigt diesen Unterschied für die 15 Schweizer mit den meisten gemeinsamen Tagen. Die oberen Athleten sind breit mit dem Ausland verbunden, vor allem mit den vielen Nationen unter «Übrige Nationen», auf die 71 % aller Auslandstage der Schweizer entfallen. Die unteren teilen ihre Tage überwiegend mit Landsleuten. Die internationale Einbindung der Schweiz hängt damit an wenigen Personen. Wichtigster ausländischer Partner ist Liechtenstein, dessen Athleten vermutlich regelmässig an Schweizer Wettkämpfen starten.

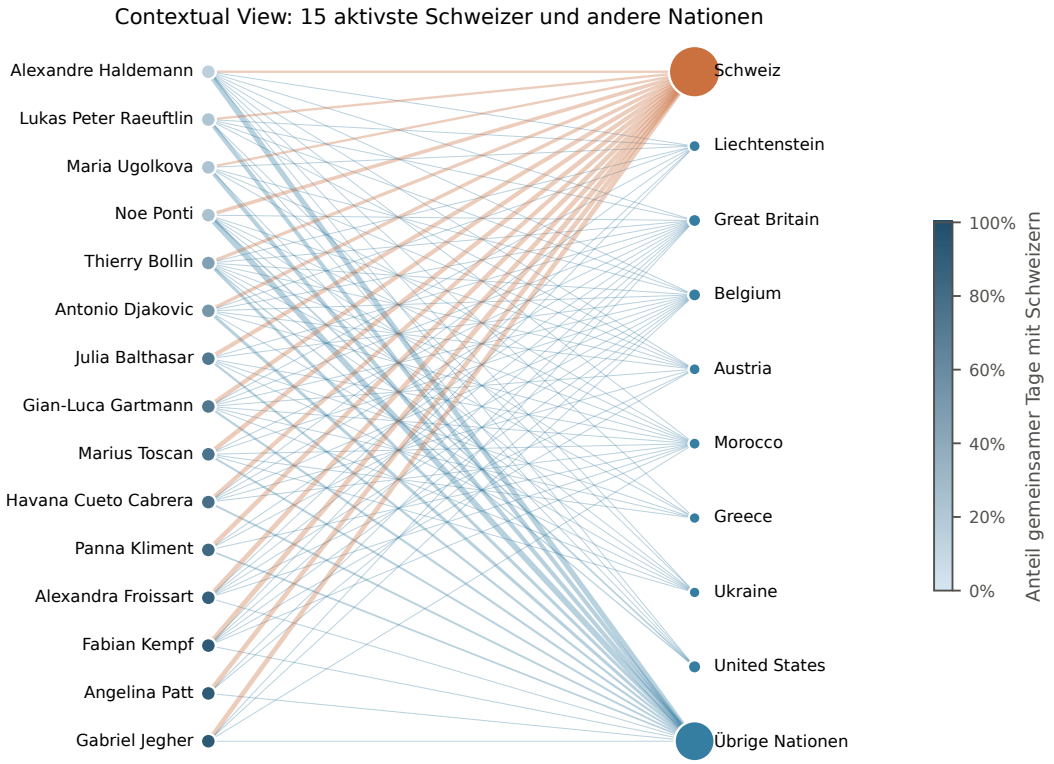


Abbildung 4.4: Contextual View für die 15 Schweizer mit den meisten gemeinsamen Tagen, sortiert von international (oben) zu national (unten). Farbe: Anteil der Tage mit Landsleuten. Rechts ihre Partner nach Nation zusammengefasst, die Kreisgrösse zeigt deren gemeinsame Tage mit den gezeigten Athleten. Linienstärke: gemeinsame Tage, orange mit Schweizern, blau mit dem Ausland. Eigene Darstellung.

4.5 Ego-Netzwerk von Michael Phelps

Als Ego wählen wir Michael Phelps, den Schwimmer mit den meisten Olympiamedaillen. Im vollständigen Graphen hat er 708 Nachbarn, im Arbeitsnetz bleiben 168 (Abbildung 4.5). Nur 17 % davon stammen aus den USA, insgesamt sind 61 Nationen vertreten. Die mittleren 50 % der Nachbarn sind zwischen 1984 und 1990 geboren. Die meisten Verbindungen entstehen an der Weltmeisterschaft 2009 in Rom (121 Nachbarn) und den Olympischen Spielen 2008 in Peking (51). Das passt zum lokalen Anstieg 2009 in Abbildung 2.1. Die stärksten Verbindungen mit vier oder fünf gemeinsamen Tagen bestehen zu Allison Schmitt, Julia Smit, Peter Vanderkaay und Darian Townsend.

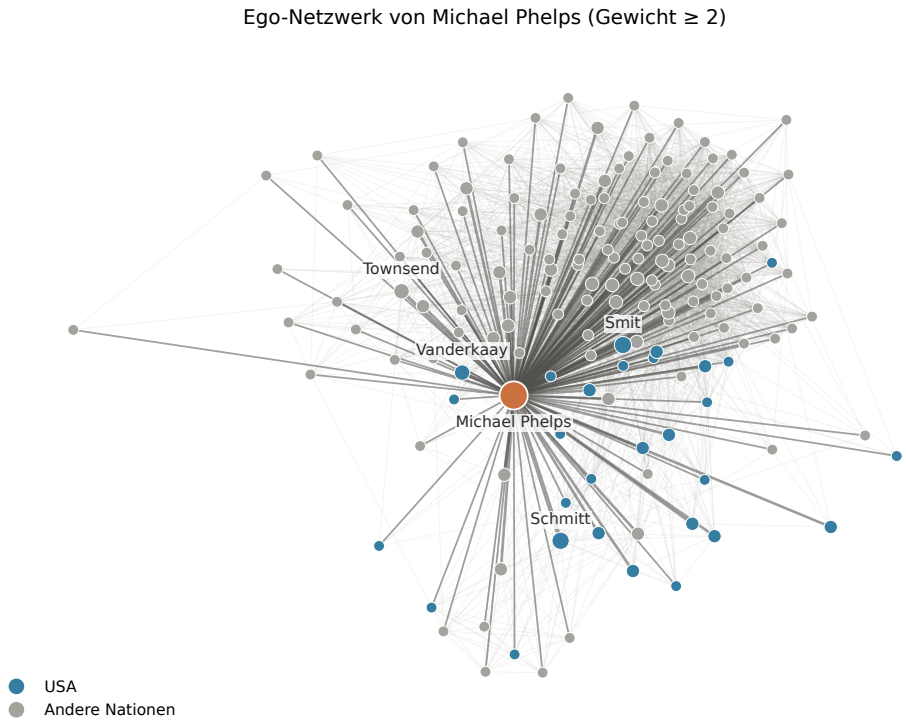


Abbildung 4.5: Ego-Netzwerk von Michael Phelps (orange) mit 168 Nachbarn, blau aus den USA, grau aus anderen Nationen. Knotengrösse und dunkle Linien zeigen die gemeinsamen Tage mit Phelps, beschriftet sind Nachbarn ab vier Tagen. Hellgraue Linien verbinden Nachbarn untereinander. Eigene Darstellung.

Unter den Nachbarn beträgt die Density 0,26, im gesamten Arbeitsnetz nur 0,0041. Diese Dichte entsteht durch die Modellierung, denn jeder Veranstaltungstag verbindet alle dort erfassten Athleten. Das Ego-Netzwerk zeigt somit vor allem die Veranstaltungen, an denen Phelps seine Bestleistungen erzielte, und keine persönlichen Kontakte.

5 Communities

Wir suchen Communities im Arbeitsnetz aus Kapitel 4. Die Connected Components sind dort bereits beschrieben. Neben 413 isolierten Athleten umfasst die Giant Component 96,6 % der Athleten.

5.1 Cliquen und k-Core

Der innerste k-Core des Arbeitsnetzes hat k = 113 und umfasst 114 Athleten aus 71 Nationen. Alle 114 sind an denselben zwei Tagen der Weltmeisterschaft 2009 in Rom erfasst. Da die Projektion alle Athleten eines Veranstaltungstags vollständig verbindet, bilden grosse Veranstaltungen automatisch Cliquen und dichte Kerne. Cliquen, n-Cliquen und k-Cores zeigen in unserem Modell deshalb vor allem einzelne Veranstaltungen. Für die Suche nach Communities verwenden wir stattdessen Verfahren, die die gesamte Netzwerkstruktur berücksichtigen.

5.2 Louvain und Label Propagation

Louvain findet mit den Kantengewichten eine Modularity von Q = 0,76, also eine ausgeprägte Community-Struktur. Neben den 413 isolierten Athleten entstehen 60 Communities, davon 44

mit mindestens zehn Athleten. Tabelle 5.1 zeigt zwei Typen. Die vier grössten Communities enthalten zusammen 48,8 % der Athleten. Sie sind international, keine Nation stellt mehr als 6 % der Mitglieder. Sie unterscheiden sich vor allem zeitlich und bilden Generationen, deren Athleten an denselben Meisterschaften starteten. C4 entstand um die Europameisterschaften der frühen 2000er-Jahre, C2 um die Weltmeisterschaft 2009, C3 um die Kurzbahn-WM 2014 mit Schwerpunkt Ostasien und C1 um die aktuellen Weltmeisterschaften. Die übrigen grossen Communities sind national oder regional, ihr häufigster Wettkampf ist meist eine nationale Meisterschaft. Elf der 26 Communities mit mindestens 150 Athleten bestehen zu mindestens 90 % aus einer Nation. Der Frauenanteil liegt in allen Communities ab 150 Athleten zwischen 41 und 55 %, was zum schwachen Geschlechtereffekt aus Kapitel 4 passt.

Tabelle 5.1: Ausgewählte Louvain-Communities im Arbeitsnetz, nummeriert nach Grösse. Jahrgang und Jahr: Median der Geburtsjahre und der Veranstaltungstage. Wettkampf: Wettkampf mit den meisten Mitgliedern. Eigene Auswertung.

	Athleten	Nationen	Grösste Nation	Jahrgang	Jahr	Wettkampf
C1	2 064	158	Australien, GB (je 5 %)	2002	2021	Weltmeisterschaften
C2	1 881	135	Südafrika (4 %)	1988	2009	WM 2009 Rom
C3	1 304	140	Japan (6 %)	1996	2015	Kurzbahn-WM 2014
C4	1 175	113	Ukraine (3 %)	1978	2001	Europameisterschaften
C8	200	12	Spanien (90 %)	1997	2018	Spanische Meisterschaften
C9	185	2	Türkei (99 %)	2002	2019	Türkische Klubmeisterschaft
C19	168	25	Schweiz (60 %)	2000	2018	Schweizer Meisterschaften

Abbildung 5.1 zeigt die vier grössten Communities im Layout von Abbildung 3.2. Sie liegen von links nach rechts in der zeitlichen Reihenfolge C4, C2, C3 und C1. Das Layout, das ohne Kenntnis der Communities oder Jahrgänge berechnet wurde, ordnet die Athleten damit entlang der Generationen an. Die übrigen, überwiegend nationalen Communities bilden vor allem den unteren Teil des Netzes.

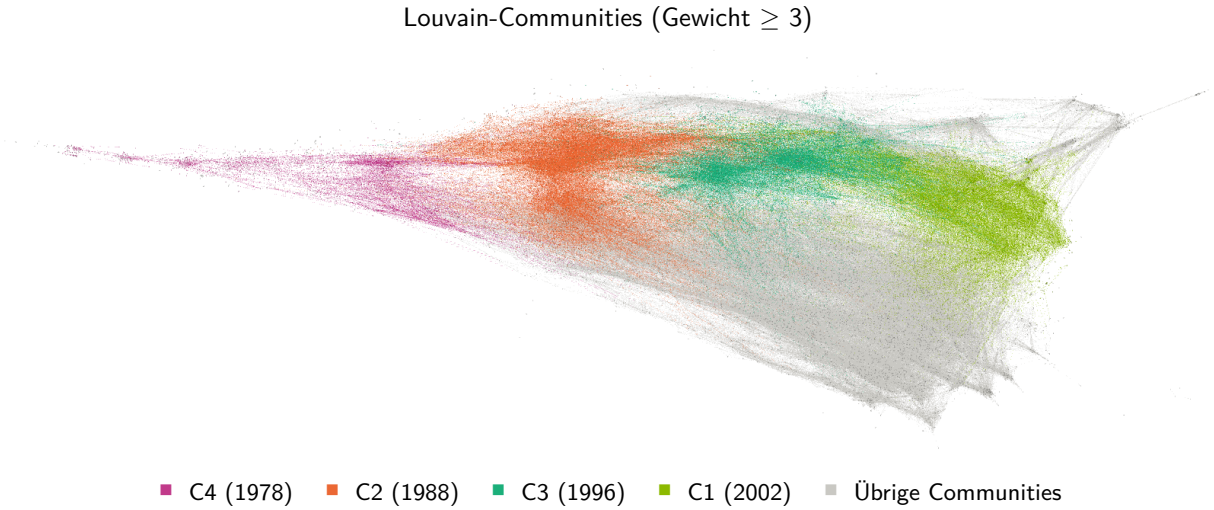


Abbildung 5.1: Athletenprojektion im Layout von Abbildung 3.2, gefärbt nach den vier grössten Louvain-Communities des Arbeitsnetzes. In Klammern der Median der Geburtsjahre. Eigene Darstellung in Gephi.

Label Propagation dient als zweites Verfahren, da es auch für grosse Netze geeignet ist. Girvan-Newman berechnet nach jeder entfernten Kante alle Edge-Betweenness-Werte neu und ist für

dieses Netz zu aufwendig. Label Propagation erreicht Q = 0,73 und findet dieselbe Grobstruktur. Die Übereinstimmung der beiden Zuordnungen beträgt 0,79 (Normalized Mutual Information, 1 = identisch). C1 und C2 werden zu 95 bzw. 94 % gleich zugeordnet. C3 und C4 teilt Label Propagation dagegen anders auf. Die Generationen sind damit robust, ihre Grenzen aber unscharf.

Louvain findet auch in zufälligen Netzen Gruppen. Wir prüfen deshalb mit einem Hypothesentest, ob die Modularity über das hinausgeht, was die Gradverteilung allein erzeugt. Als Referenz dienen 100 Configuration Models mit derselben Gradverteilung wie das Arbeitsnetz. Da diese keine Gewichte kennen, vergleichen wir ungewichtet. Das Arbeitsnetz erreicht so Q = 0,71, die Referenz-Netzwerke im Mittel 0,11 und höchstens 0,11. Keines erreicht den beobachteten Wert, die Community-Struktur ist damit signifikant ($p < 0{,}01$, $\alpha = 0{,}05$).

5.3 Communities und Nationen

45,7 % der Athleten liegen in einer Community, die von ihrer eigenen Nation dominiert wird. Im Median hat eine Nation die Hälfte ihrer Athleten in derselben Community. Das entspricht der nationalen Prägung aus Kapitel 4. Wer vor allem national startet, bleibt in der nationalen Community, international startende Athleten wechseln in die Generationen. Michael Phelps gehört zu C2, der Generation um die Weltmeisterschaft 2009. Von den 160 Schweizern liegen 101 in C19, zusammen mit Athleten aus Zypern und Liechtenstein, 27 in C2 und 18 in C4. Dies bestätigt die Contextual View. Die Mehrheit ist national vernetzt, die international startenden Schweizer verteilen sich auf die Generationen.

5.4 Communities im Nationennetz

Im Nationennetz findet Louvain fünf Communities, darunter St. Kitts und Nevis als isolierte Nation. Mit Q = 0,20 ist die Struktur schwach, was zur hohen Density des Nationennetzes passt. Die Gruppen sind dennoch plausibel. Europa bildet mit 50 Nationen eine Gruppe, Asien-Pazifik eine zweite zusammen mit den grossen Schwimmnationen USA, Kanada, Australien, Brasilien und Südafrika (40 Nationen). Die dritte umfasst viele kleinere Schwimmnationen aus Lateinamerika, Karibik, Afrika und dem Nahen Osten (87 Nationen). Portugal bildet mit Angola, Mosambik und Malawi eine eigene kleine Gruppe.

6 Wichtigkeit von Knoten & Knotengruppen

Wir messen die Zentralität im Arbeitsnetz mit 13 156 Athleten und 357 219 Kanten. Degree und Weighted Degree berechnen wir für alle Athleten. Closeness, Betweenness und Eigenvector setzen einen zusammenhängenden Graphen voraus und beziehen sich deshalb auf die Giant Component mit 12 709 Athleten. Die Kantengewichte verwenden wir nur beim Weighted Degree, der die gemeinsamen Tage mit allen Nachbarn summiert. Für Distanzen eignen sie sich nicht, da ein hohes Gewicht eine engere Verbindung bedeutet und keine längere Strecke. Die Closeness berechnen wir als normierte Summe der inversen Distanzen

$$C_H(v) = \frac{1}{n-1} \sum_{u \neq v} \frac{1}{d(u,v)}.$$

Prestige-Masse entfallen, da unser Netz ungerichtet ist.

6.1 Zentrale Athleten

Abbildung 6.1 zeigt die fünf höchsten Werte je Mass. Den höchsten Degree hat Katinka Hosszú mit 543 Nachbarn, sie erreicht auch die höchste Closeness. Ein hoher Degree bedeutet bei uns

aber nicht viele Wettkämpfe. Hosszú ist an 41 Veranstaltungstagen erfasst, Sheng-Yo Ting mit 498 Nachbarn sogar nur an 12. Der Median aller Athleten liegt bei 16 Tagen. Viele Nachbarn entstehen also durch wenige, aber sehr grosse internationale Veranstaltungen.

Die Eigenvector-Zentralität ist hoch, wenn die Nachbarn selbst zentral sind. Alle zehn höchsten Werte liegen im innersten k-Core aus Kapitel 5, also bei Athleten der Weltmeisterschaft 2009 in Rom. Von den ersten hundert sind es 76 %. Darunter sind auffällig viele Athleten kleiner Nationen wie Simbabwe, Macau, Namibia oder der Cayman Islands. Für sie ist eine Weltmeisterschaft oft der Ort ihrer Bestleistung, wodurch sie im dichtesten Teil des Netzes liegen.

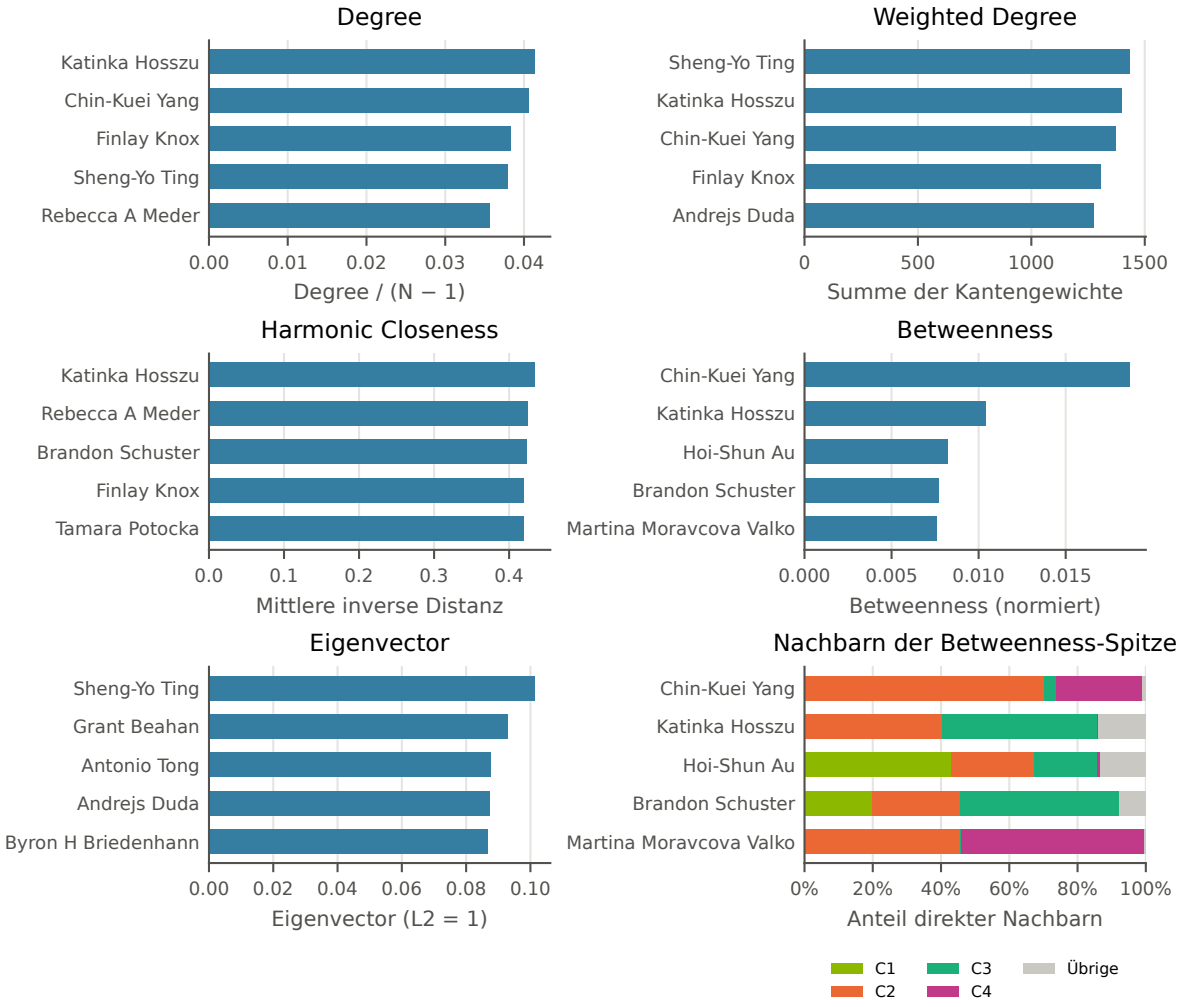


Abbildung 6.1: Die fünf höchsten Werte je Mass. Degree und Weighted Degree für alle Athleten, die übrigen Masse für die Giant Component. Unten rechts die direkten Nachbarn der fünf Athleten mit der höchsten Betweenness nach Community. Eigene Auswertung.

Die Betweenness misst, wie oft ein Athlet auf kürzesten Wegen zwischen anderen liegt. Die höchsten Werte haben Chin-Kuei Yang (0,0187), Hosszú (0,0104) und Hoi-Shun Au (0,0083). Au hat nur 156 Nachbarn und liegt beim Degree auf Rang 690. Alle zehn Athleten mit der höchsten Betweenness haben Nachbarn in mindestens drei der vier Generationen aus Kapitel 5. Yang verbindet vor allem C2 (375 Nachbarn) mit der älteren C4 (135), Martina Moravcová Valko ebenso C4 (94) mit C2 (80). Jan Sefl verbindet dagegen die fast vollständig tschechische Community C32 mit den internationalen Generationen. Von seinen 219 Nachbarn liegen 132

in C1 bis C3. Hohe Betweenness kennzeichnet somit Athleten an den Übergängen zwischen Generationen oder zwischen nationaler und internationaler Ebene.

Tabelle 6.1 ordnet vier bekannte Athleten ein. Michael Phelps liegt bei keinem Mass unter den ersten 100 und bei der Betweenness nur auf Rang 1 376. Von seinen 168 Nachbarn liegen 155 in C2, eine Brücke zwischen Generationen ist er im Netz also nicht. László Cseh liegt dagegen bei Betweenness (Rang 23) und Closeness (28) deutlich höher als beim Degree (131). Moravcová Valko erreicht bei der Betweenness sogar Rang 5, beim Degree nur Rang 517.

Tabelle 6.1: Vier ausgewählte Athleten. Werte und in Klammern der Rang, gleiche Werte erhalten denselben Rang. C: Community aus Kapitel 5. Eigene Auswertung.

Athlet	C	Degree	Gewichtet	Closeness	Betweenness	Eigenvector
Katinka Hosszú	3	543 (1)	1 398 (2)	0,4332 (1)	0,01040 (2)	0,0727 (26)
Michael Phelps	2	168 (583)	383 (809)	0,3633 (855)	0,00045 (1 376)	0,0295 (291)
László Cseh	2	279 (131)	656 (154)	0,4041 (28)	0,00537 (23)	0,0451 (152)
Martina Moravcová Valko	4	176 (517)	379 (832)	0,3553 (1 243)	0,00762 (5)	0,0250 (357)

Die Masse hängen zusammen, sind aber nicht austauschbar. Die Rangkorrelation nach Spearman reicht von 0,96 zwischen Degree und Weighted Degree bis 0,47 zwischen Weighted Degree und Eigenvector. Alle Werte beschreiben gemeinsame Veranstaltungstage gespeicherter Bestleistungen. Hohe Zentralität zeigt deshalb, an welchen Veranstaltungen ein Athlet seine Bestleistungen erzielte, und keine persönlichen Kontakte.

6.2 Leistung und Zentralität

Sind stärkere Schwimmer zentraler? Als Leistung verwenden wir die maximalen FINA-Punkte eines Athleten. Für 12 708 der 12 709 Athleten der Giant Component liegt ein Punktewert vor. Wir prüfen den Zusammenhang mit einem monadischen Permutationstest. Die Nullhypothese lautet, dass Punkte und Zentralität nicht zusammenhängen. Dazu werden die Punkte 9 999-mal zufällig auf die Athleten verteilt, Netzwerk und Zentralitäten bleiben unverändert. Teststatistik und Effektgrösse ist die Rangkorrelation ρ nach Spearman, das Signifikanzniveau beträgt $\alpha = 0{,}05$.

Alle fünf Zusammenhänge sind positiv (Abbildung 6.2). Am stärksten sind sie bei der Closeness ($\rho = 0{,}36$) und der Betweenness (0,33), es folgen Eigenvector (0,29), Degree (0,23) und Weighted Degree (0,17). Keine Permutation erreicht einen der beobachteten Werte ($p = 0{,}0001$, nach Holm-Korrektur für die fünf Tests $p = 0{,}0005$). Stärkere Schwimmer liegen also näher am Zentrum des Netzes und häufiger auf kürzesten Wegen. Die Effekte sind aber schwach bis mässig.

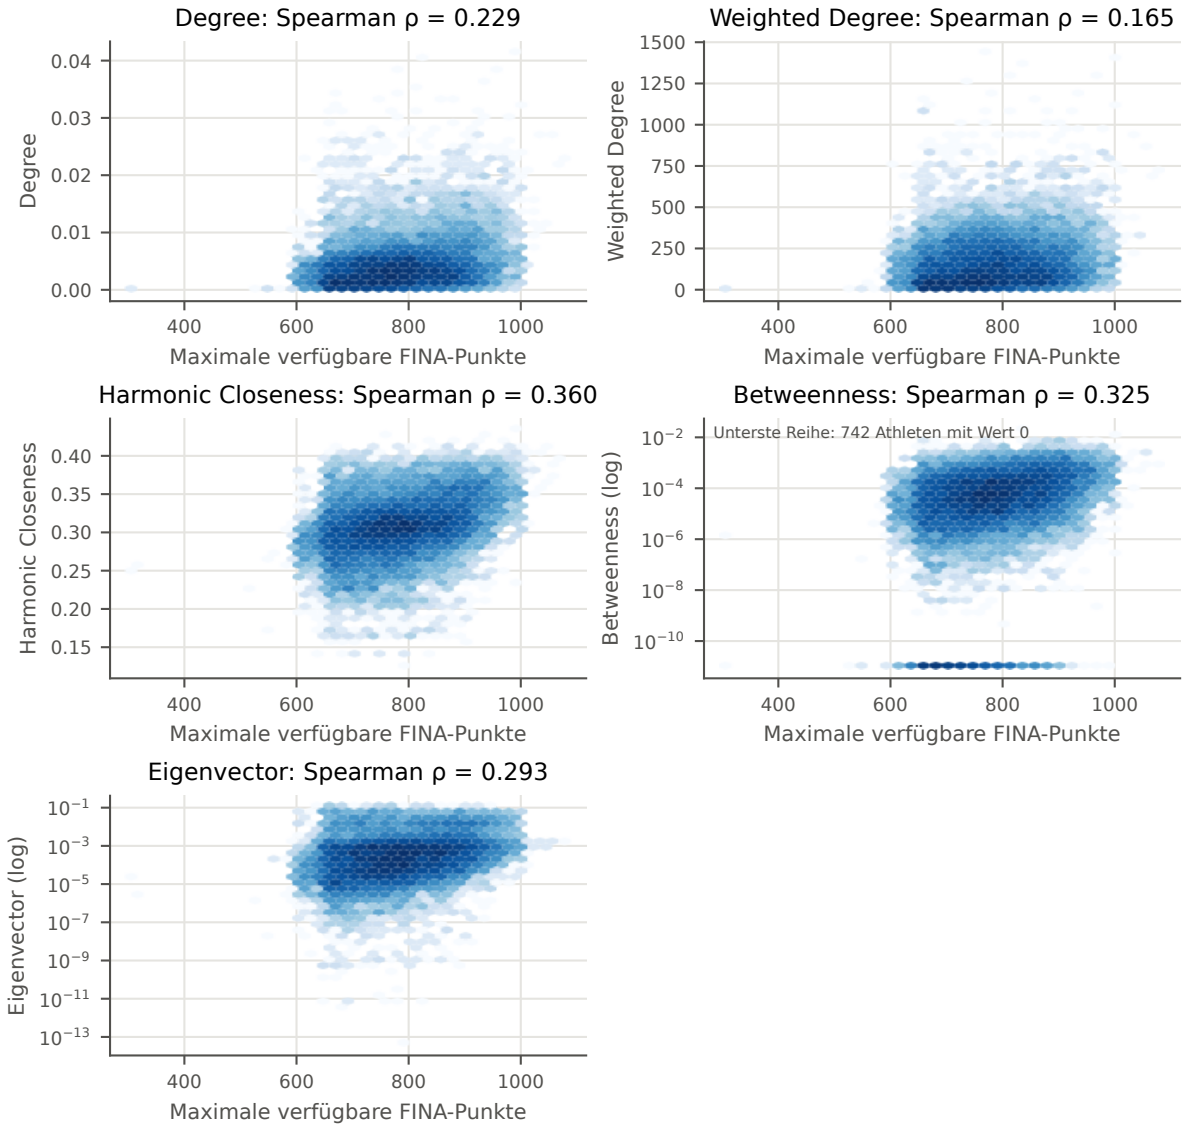


Abbildung 6.2: Maximale FINA-Punkte und Zentralität für 12 708 Athleten der Giant Component. Dunklere Felder enthalten mehr Athleten (logarithmische Farbskala). Betweenness und Eigenvector mit logarithmischer y-Achse. Eigene Auswertung.

Ein Teil des Zusammenhangs kann am Datenumfang liegen. Je Athlet sind 2 bis 100 Bestleistungen gespeichert, im Median 20. Ihre Zahl korreliert sowohl mit den maximalen Punkten ($\rho = 0{,}27$) als auch mit dem Weighted Degree (0,49). Der Test belegt deshalb keinen kausalen Einfluss der Leistung.

6.3 Nationalteams und Generationen

Für Gruppen von Athleten verwenden wir Degree und Closeness auf Gruppenebene. Mit $d(v, S)$ als Distanz zum nächsten Mitglied der Gruppe S und $N = 13\,156$ gilt

$$C_D(S) = \frac{|\{v \notin S : d(v,S) = 1\}|}{N - |S|}, \qquad C_H(S) = \frac{1}{N - |S|} \sum_{v \notin S} \frac{1}{d(v,S)}.$$

Der Group Degree ist also der Anteil der Aussenstehenden mit direkter Verbindung zur Gruppe, die Group Closeness der Mittelwert ihrer inversen Distanzen. Die Group Betweenness lassen wir

weg, da sie für ein Netz dieser Grösse zu aufwendig ist. Als Gruppen dienen die 22 Nationen mit mindestens 200 Athleten aus Kapitel 4 und die Generationen C1 bis C4 aus Kapitel 5.

Die USA erreichen mit 206 Athleten 2 905 Aussenstehende direkt (Group Degree 0,224) und haben auch die höchste Group Closeness (0,581). Japan folgt mit 0,217, die Türkei liegt bei beiden Massen am tiefsten (0,108 und 0,513). Der Group Degree hängt stark mit dem nationalen Anteil aus Kapitel 4 zusammen (Spearman −0,82). Je mehr Tage die Athleten einer Nation mit Landsleuten teilen, desto weniger Aussenstehende erreicht das Team.

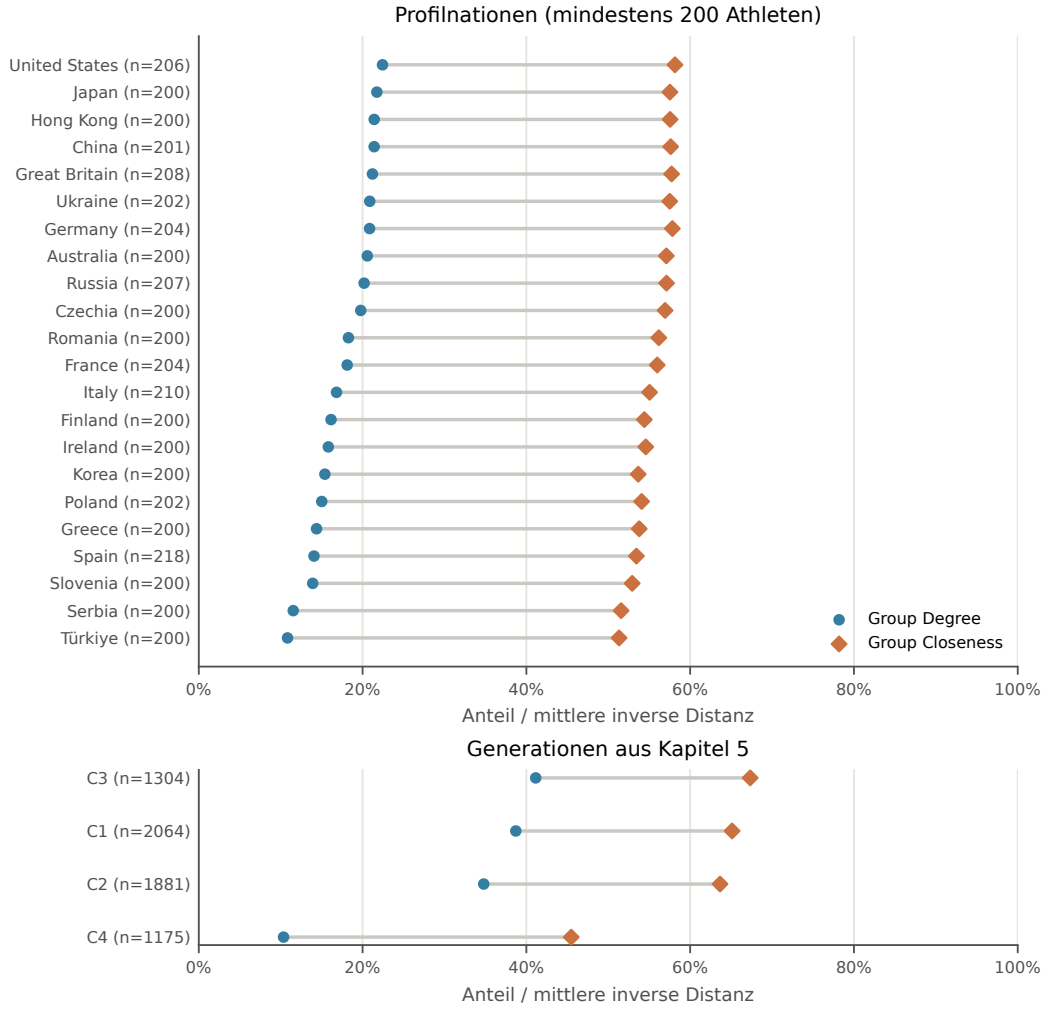


Abbildung 6.3: Group Degree (blau) und Group Closeness (orange) der Nationen mit mindestens 200 Athleten und der Generationen C1 bis C4. In Klammern die Gruppengrösse. Eigene Auswertung.

Bei den Generationen ist C3 am zentralsten. Sie erreicht mit 1 304 Athleten 4 876 Aussenstehende direkt (0,411) und liegt damit vor der grösseren C1 (0,387) und C2 (0,348). C3 liegt zeitlich und im Layout von Abbildung 5.1 zwischen C2 und C1. Die älteste Generation C4 erreicht dagegen nur 1 240 Aussenstehende (0,103). Ihre Bestleistungen stammen vermutlich zu selten von denselben Veranstaltungen wie jene späterer Athleten. Da die Generationen deutlich grösser sind als die Nationalteams, vergleichen wir die Werte nur innerhalb der beiden Gruppenarten.

7 Zusammenhalt des Netzwerks

Nachdem Kapitel 6 gezeigt hat, wer im Netz zentral ist, fragen wir nun, was das Netz zusammenhält. Sind es einzelne Athleten oder die Veranstaltungen, an denen sie sich treffen? Grundlage ist wieder das Arbeitsnetz mit 13 156 Athleten und 357 219 Kanten.

7.1 Kennzahlen und Nullmodell

Das Arbeitsnetz ist mit einer Density von 0,0041 sehr dünn, aber lokal stark vernetzt. Das Clustering, also der mittlere Anteil verbundener Nachbarspaare, beträgt 0,49. Zwischen zwei Athleten der Giant Component liegen höchstens elf Schritte (Diameter). Die Degree-Zentralisierung von 0,037 und die Betweenness-Zentralisierung von 0,018 sind sehr tief. Kein einzelner Athlet dominiert das Netz.

Ein Teil dieser Struktur entsteht durch die Projektion, da jeder Veranstaltungstag seine Athleten vollständig verbindet. Das gewöhnliche Configuration Model berücksichtigt das nicht und ist deshalb kein fairer Vergleich. Wir verwenden deshalb das bipartite Configuration Model (Newman et al., 2001), das die Projektion berücksichtigt. Dafür verteilen wir die Athleten 100-mal zufällig auf die Teilnahmen. Jeder Veranstaltungstag behält seine Grösse, jeder Athlet seine Zahl an Tagen. Die Zahl der Begegnungen bleibt damit gleich, nur ihre Verteilung auf Athletenpaare ist zufällig. Danach projizieren und filtern wir wie im Original. Die Nullhypothese lautet, dass die Struktur allein aus diesen Grössen entsteht.

Tabelle 7.1: Arbeitsnetz und Nullmodell mit zufällig verteilten Teilnahmen (100 Referenz-Netzwerke). Eigene Auswertung.

	Arbeitsnetz	Nullmodell Mittel	Nullmodell Maximum
Kanten	357 219	35 930	36 692
Clustering	0,49	0,04	0,04
Anteil Giant Component	96,6 %	65,7 %	66,6 %

Tabelle 7.1 zeigt einen deutlichen Unterschied. Das Arbeitsnetz hat rund zehnmal so viele Kanten wie die Referenz-Netzwerke, und keines erreicht einen der beobachteten Werte ($p < 0{,}01$, $\alpha = 0{,}05$). Wiederholte Begegnungen sind also kein Zufall. Dieselben Athleten erzielen immer wieder am selben Tag ihre Bestleistungen, etwa an nationalen Meisterschaften und regelmässigen internationalen Wettkämpfen. Das passt zu den nationalen Communities aus Kapitel 5.

7.2 Robustheit

Abbildung 7.1 zeigt, wie sich die Giant Component verändert, wenn wir schrittweise Athleten oder Veranstaltungstage entfernen. Athleten entfernen wir nach absteigender Betweenness aus Kapitel 6, nach Degree oder zufällig. Bei den Veranstaltungstagen beginnen wir mit den internationalsten, gemessen an der Zahl der Nationen am Tag, mit den grössten oder mit zufälligen Tagen. Nach jedem Schritt wird neu projiziert.

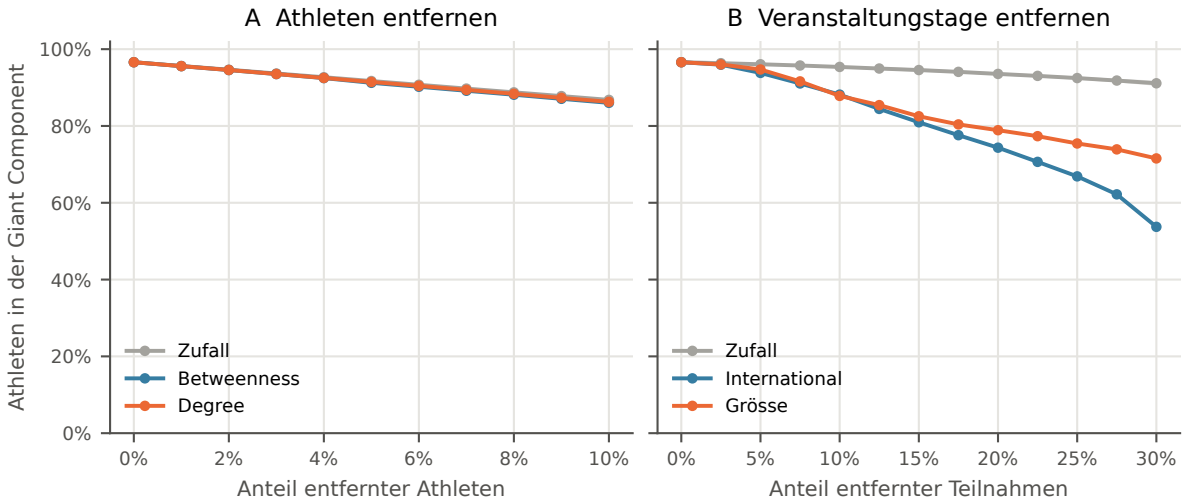


Abbildung 7.1: Anteil aller Athleten in der Giant Component beim Entfernen von Athleten (A) und Veranstaltungstagen (B). In B zeigt die x-Achse den Anteil entfernter Teilnahmen. Grau: Mittel von zehn zufälligen Reihenfolgen, die sich um höchstens 1,4 Prozentpunkte unterscheiden. Eigene Auswertung.

Das Entfernen einzelner Athleten schadet dem Netz kaum. Auch ohne die 10 % mit der höchsten Betweenness bleiben 86,0 % aller Athleten in der Giant Component, bei zufällig entfernten Athleten 86,8 %. Verloren gehen fast nur die entfernten Athleten selbst. Auch die 184 Cut-Vertices trennen jeweils höchstens drei Athleten ab, im Median einen. Sie binden einzelne Athleten am Rand an, ein verwundbarer Kern existiert nicht.

Ganz anders bei den Veranstaltungstagen. Fehlen die internationalsten Tage mit zusammen 30 % der Teilnahmen, bleiben nur 53,7 % der Athleten in der Giant Component, bei zufälligen Tagen 91,1 %. Die grössten Tage tragen zwar mehr Kanten, ihr Entfernen zerlegt das Netz aber weniger (71,5 %). Entscheidend ist also nicht die Grösse eines Tages, sondern dass er Athleten vieler Nationen zusammenbringt. Internationale Meisterschaften wie die Weltmeisterschaft 2009 in Rom mit 105 Nationen an einem Tag halten das Netz zusammen. Das erklärt auch, warum ihr Kern in Kapitel 5 und die Eigenvector-Spitze in Kapitel 6 so hervortreten.

7.3 Generationen im Vergleich

Tabelle 7.2 vergleicht die Teilnetze der vier Generationen aus Kapitel 5 in zeitlicher Reihenfolge. Da die Density von der Grösse abhängt, betrachten wir vor allem den mittleren Grad.

Tabelle 7.2: Teilnetze der Generationen im Arbeitsnetz, sortiert nach Jahrgang. Mittlerer Grad: durchschnittliche Zahl Nachbarn innerhalb der Generation. Zentralisierung: Degree-Zentralisierung nach Freeman. Eigene Auswertung.

	Jahrgang	Athleten	Mittlerer Grad	Clustering	Diameter	Zentralisierung
C4	1978	1 175	27,9	0,52	9	0,11
C2	1988	1 881	67,7	0,53	7	0,21
C3	1996	1 304	52,9	0,60	7	0,23
C1	2002	2 064	50,1	0,54	7	0,18

Die Generation mit Jahrgang 1988 (C2) ist am dichtesten vernetzt. Ein Drittel ihrer Teilnahmen fällt in die Jahre 2008 und 2009, in denen der Datensatz bereits in Kapitel 2 einen Anstieg zeigt. Ihre Bestleistungen konzentrieren sich damit auf wenige Saisons und dieselben Meisterschaften, allen voran die Weltmeisterschaft 2009 in Rom. Die zentralsten Athleten von C2 sind Sheng-Yo Ting, Andrejs Duda und Grant Beahan, also dieselben wie an der Eigenvector-Spitze in Kapitel 6. Auch in C3 prägen Athleten kleinerer Nationen wie Nordmazedonien, Nicaragua oder der Philippinen die Spitze. Wenige Athleten, die an vielen grossen Meisterschaften starten, erklären so die höhere Zentralisierung dieser beiden Generationen.

Die älteste Generation C4 ist am losesten verbunden. 77 % ihrer Teilnahmen liegen vor 2005, im gesamten Datensatz sind es nur 5 %. Ein Athlet von C4 hat im Median nur sieben gespeicherte Veranstaltungstage, in C2 sind es 13. Die geringe Vernetzung von C4 spiegelt deshalb vor allem, dass ältere Bestleistungen seltener erfasst sind. Das Clustering ist in allen Generationen ähnlich hoch, da es vor allem aus der Projektion entsteht.

8 Assortativität

Kapitel 7 hat gezeigt, dass sich Athleten wiederholt treffen. Nun fragen wir, wer sich trifft. Verbinden sich Athleten bevorzugt mit ähnlichen Athleten? Wir untersuchen die Assortativität nach Nation, Geschlecht, Jahrgang, Leistung und Degree im Arbeitsnetz. Für kategorische Attribute berechnen wir sie über die Mixing Matrix, für numerische als Pearson-Korrelation der Werte an beiden Enden jeder Kante. Als Leistung dient wie in Kapitel 6 der maximale FINA-Punktewert.

8.1 Gesamtnetz

Für Nation, Geschlecht, Jahrgang und Leistung prüfen wir die Nullhypothese, dass das Attribut nicht mit den Kanten zusammenhängt. Dazu verteilen wir die Werte 10 000-mal zufällig auf die Athleten, die Netzwerkstruktur bleibt wie in Kapitel 4 unverändert. Der Degree entsteht aus dem Netz selbst. Für ihn vergleichen wir deshalb mit den 100 Referenz-Netzwerken des bipartiten Configuration Model aus Kapitel 7. Das Signifikanzniveau beträgt $\alpha = 0{,}05$ mit Holm-Korrektur über die fünf Tests.

Tabelle 8.1: Assortativität im Arbeitsnetz. Referenz für Nation, Geschlecht, Jahrgang und Leistung sind 10 000 Permutationen der Attribute, für den Degree 100 Referenz-Netzwerke des bipartiten Configuration Model. Eigene Auswertung.

Attribut	r	Referenz Mittel	Referenz Maximum	p
Jahrgang	0,85	0,00	0,01	$< 0{,}0001$
Nation	0,42	0,00	0,00	$< 0{,}0001$
Degree	0,40	0,12	0,16	$< 0{,}01$
Leistung	0,37	0,00	0,01	$< 0{,}0001$
Geschlecht	0,04	0,00	0,01	$< 0{,}0001$

Alle Attribute sind signifikant assortativ (Tabelle 8.1), auch nach Holm-Korrektur. Am stärksten verbinden sich Athleten gleichen Jahrgangs, danach folgen Nation, Degree und Leistung. Das Geschlecht ist mit $r = 0{,}04$ vernachlässigbar, wie schon in Kapitel 4. Auch die Degree-Assortativität geht klar über das bipartite Configuration Model hinaus. Athleten mit vielen Kontakten treffen sich also häufiger untereinander, als die Projektion allein erklärt. Das passt zu Kapitel 7, wo internationale Meisterschaften das Netz zusammenhalten. In Kapitel 4 hatten wir für die Nation eine

Korrelation von 0,25 berechnet. Sie bezog sich auf alle Athletenpaare, die Assortativität dagegen nur auf die Kanten. Beide messen dieselbe Tendenz, nur anders normiert. Die Rangvarianten bestätigen die Werte, Ausreisser treiben sie also nicht.

Der Jahrgang ist der stärkste Befund. Verbundene Athleten unterscheiden sich im Median um drei Jahre, zufällige Paare um neun (Abbildung 8.1). Fast die Hälfte der verbundenen Paare liegt höchstens zwei Jahre auseinander, bei zufälligen Paaren ist es ein Sechstel. Das erklärt die Generationen-Communities aus Kapitel 5.

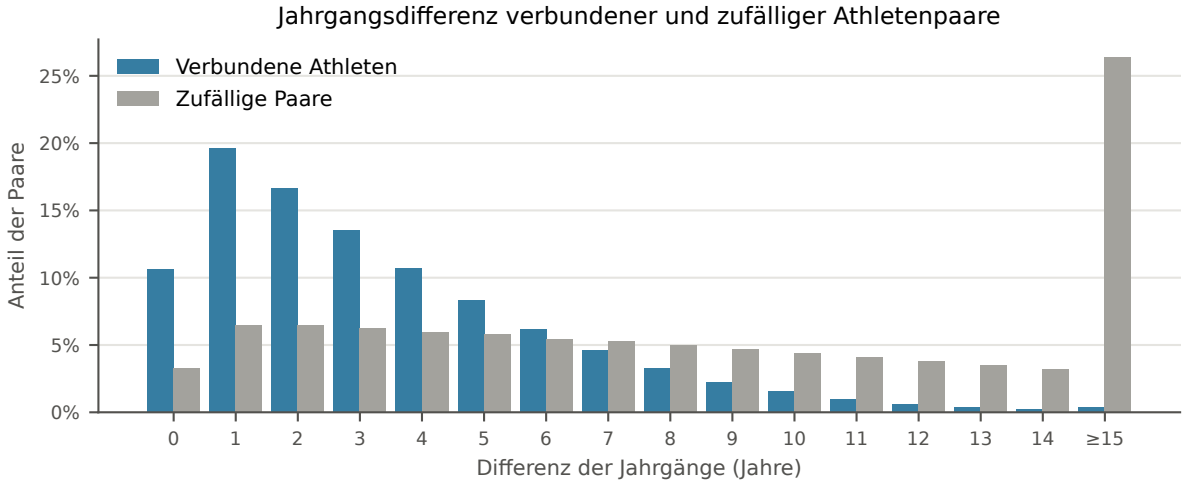


Abbildung 8.1: Differenz der Jahrgänge für verbundene Athleten (blau) und gleich viele zufällige Paare mit bekanntem Jahrgang (grau). Die letzte Klasse fasst Differenzen ab 15 Jahren zusammen. Eigene Auswertung.

8.2 Elite-Club oder Altersklassen

Ein globaler Wert kann lokale Muster verdecken. Abbildung 8.2 zeigt die Assortativität nach Leistung und Jahrgang deshalb getrennt für die Generationen und die elf nationalen Communities aus Kapitel 5. Für die nationalen Communities zentrieren wir die Werte vorher je Community. Sonst würden die unterschiedlichen Leistungsniveaus der Nationen eine Assortativität vortäuschen.

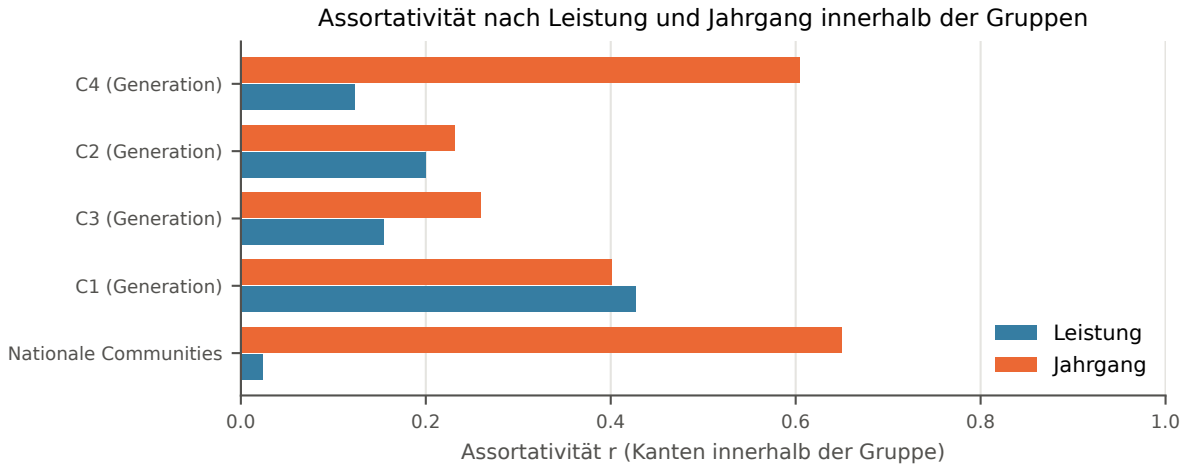


Abbildung 8.2: Assortativität nach Leistung (blau) und Jahrgang (orange) für Kanten innerhalb der Generationen und der elf nationalen Communities. Für die nationalen Communities sind die Werte je Community zentriert. Eigene Auswertung.

Die Muster unterscheiden sich deutlich. In der jüngsten Generation C1 treffen sich starke Schwimmer bevorzugt mit starken ($r = 0{,}43$). In den älteren Generationen ist dieser Effekt schwächer (0,12 bis 0,20). Innerhalb der nationalen Communities fehlt er fast ganz ($r = 0{,}02$, jede einzelne zwischen $-0{,}01$ und 0,05), dafür prägt dort der Jahrgang besonders stark ($r = 0{,}65$). National treffen sich also Gleichaltrige unabhängig von ihrem Niveau, etwa an Meisterschaften mit Altersklassen. Einen Elite-Club, in dem sich Starke mit Starken treffen, gibt es erst international und vor allem in der aktuellen Generation. Kapitel 6 hat gezeigt, dass stärkere Schwimmer zentraler sind. Hier zeigt sich, wo sie sich treffen.

Die Leistungsassortativität bleibt fast gleich, wenn wir vom Punktewert den Mittelwert desselben Jahrgangs abziehen ($r = 0{,}36$) oder den Mittelwert desselben Jahrs der besten Leistung ($r = 0{,}35$). Sie entsteht also nicht nur dadurch, dass verbundene Athleten gleich alt sind oder ihre Bestleistung in derselben Saison erzielten, deren Punkte durch Punktetabellen oder Hightech-Anzüge ähnlich verschoben sind.

Die Werte beschreiben Zusammenhänge und keine Ursachen. Da die TOP100-Auswahl eine eher homogene Leistungselite abbildet, unterschätzen sie die Leistungsassortativität wahrscheinlich eher. Für die älteste Generation C4 ist zudem die dünnere Datenlage aus Kapitel 7 zu berücksichtigen.

9 Link Prediction

Die bisherigen Kapitel beschreiben, wer sich trifft. Zum Schluss fragen wir, ob sich daraus vorhersagen lässt, wer sich künftig trifft. Lassen sich neue Begegnungen aus der bisherigen Netzwerkstruktur vorhersagen? Und schlägt die Netzwerkstruktur einfache Faustregeln wie gleiche Nation oder ähnlicher Jahrgang? Dazu folgen wir dem zeitlichen Experiment von Liben-Nowell und Kleinberg (2007).

9.1 Versuchsaufbau

Wir teilen die Veranstaltungstage in einen Trainingszeitraum von 2016 bis 2019 und einen Testzeitraum von 2021 bis 2025. Das Jahr 2020 lassen wir aus. Wegen der Corona-Pandemie

fanden kaum Wettkämpfe statt. Der Datensatz enthält für 2020 nur 5 749 Teilnahmen, in den Jahren davor und danach jeweils über 13 000. Zudem trennt die Lücke die beiden Zeiträume klar.

Vorhergesagt wird, welche Athleten künftig am selben Tag eine Bestleistung erzielen. Wir betrachten dabei Athleten, die in beiden Zeiträumen an mindestens drei Veranstaltungstagen erfasst sind. Diese Auswahl ist erst im Nachhinein möglich, ebenso die Zahl der neuen Kanten, die wir für die Auswertung verwenden. Eine echte Vorhersage wäre deshalb schwieriger. Das Trainingsnetz enthält alle 7 024 Athleten des Trainingszeitraums mit 260 719 Kanten. Anders als im Arbeitsnetz aus Kapitel 4 genügt hier ein gemeinsamer Tag für eine Kante. Sonst würden Paare, die sich bereits begegnet sind, als neue Kandidaten gelten. Kandidaten sind alle Paare im Kern, die sich im Training nicht begegnet sind. Eine neue Kante liegt vor, wenn sich ein solches Paar im Testzeitraum mindestens einmal trifft (Tabelle 9.1). Da nur Bestleistungen gespeichert sind und eine Verbesserung den früheren Tag ersetzt, kann eine neue Kante auch eine frühere, nicht mehr erfasste Begegnung sein.

Tabelle 9.1: Datensplit der Hauptanalyse. Trainingskanten zählen Paare innerhalb des Kerns, Zufall ist der Anteil neuer Testkanten an allen Kandidaten. Eigene Auswertung.

Kernathleten	Trainingskanten	Kandidaten	Neue Testkanten	Zufall
3 017	50 792	4 498 844	121 753	2,7 %

Wir vergleichen vier Netzwerkverfahren mit drei Faustregeln. Common Neighbours zählt gemeinsame Nachbarn, Adamic-Adar gewichtet dabei Nachbarn mit wenigen Kontakten stärker. Preferential Attachment multipliziert nur die Zahl der Nachbarn beider Athleten. Soundarajan-Hopcroft zählt wie Common Neighbours und gibt einen Bonus für jeden gemeinsamen Nachbarn, der mit beiden Athleten in derselben Community liegt. Die Communities bestimmen wir dafür mit Louvain neu auf dem Trainingsnetz, damit keine Information aus dem Testzeitraum einfliesst. Die Faustregeln nutzen keine Netzwerkstruktur. Sie bevorzugen Paare gleicher Nation, ähnlichen Jahrgangs oder zuerst gleicher Nation und darin ähnlichen Jahrgangs.

Wie bei Liben-Nowell und Kleinberg sortieren wir die Kandidaten nach ihrem Score und prüfen die ersten $K = 121\,753$ Paare, also so viele, wie tatsächlich neue Kanten entstehen. Der Anteil richtiger Paare darunter ist die Precision@K. Geteilt durch die Trefferquote einer zufälligen Auswahl von 2,7 % ergibt sich der Faktor gegenüber Zufall. Paare mit gleichem Score ordnen wir zufällig. Bei zehn verschiedenen Zufallsreihenfolgen ändert sich die Precision@K um höchstens 0,15 Prozentpunkte.

9.2 Ergebnisse

Die Netzwerkverfahren ausser Preferential Attachment treffen fünf- bis sechsmal so oft wie der Zufall (Abbildung 9.1). Am besten ist Soundarajan-Hopcroft mit einer Precision@K von 16,7 %. Die einfache Faustregel gleiche Nation erreicht aber 25,1 %, kombiniert mit dem Jahrgang 25,6 %. Die Profilnation stammt allerdings aus dem Jahr 2025. Hat ein Athlet seither die Nation gewechselt, kann das die Nationsregel leicht begünstigen. Die Antwort auf unsere Frage ist damit klar. Die Netzwerkstruktur sagt neue Begegnungen deutlich besser voraus als der Zufall, aber schlechter als die Nation allein.

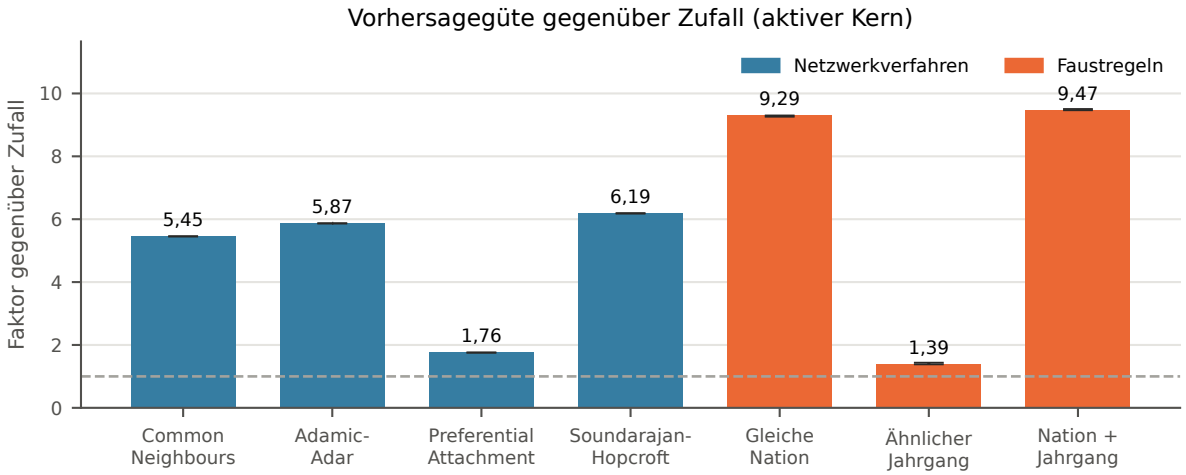


Abbildung 9.1: Faktor gegenüber Zufall je Verfahren im aktiven Kern. Blau Netzwerkverfahren, orange Faustregeln, die gestrichelte Linie markiert den Zufall (Faktor 1). Die schwarzen Striche zeigen die Spannweite über zehn Zufallsreihenfolgen bei gleichen Scores. Eigene Auswertung.

Fast ein Viertel der neuen Begegnungen (24,0 %) findet zwischen Landsleuten statt, obwohl Landsleute nur 1,2 % aller Kandidatenpaare ausmachen. Von den 55 986 Kandidatenpaaren aus Landsleuten begegnet sich mehr als die Hälfte (52,2 %) im Testzeitraum, über alle Kandidaten sind es 2,7 %. Nationale Meisterschaften wiederholen sich jedes Jahr und bringen Landsleute, die sich bisher nicht begegnet sind, häufig zusammen. Das passt zu den wiederholten Begegnungen aus Kapitel 7 und zur nationalen Assortativität aus Kapitel 8. Die Netzwerkverfahren erkennen dieses Muster nur teilweise. Unter den besten Paaren von Common Neighbours, Adamic-Adar und Soundarajan-Hopcroft verbinden 17 bis 20 % Landsleute. Vermutlich prägen die internationalen Veranstaltungen, die nach Kapitel 7 das Netz zusammenhalten, auch die gemeinsamen Nachbarn. Auch die Communities im Trainingsnetz sind gemischt, im Mittel stellt die grösste Nation nur 34 % ihrer Mitglieder. Der Community-Bonus hebt die Precision@K gegenüber Common Neighbours dennoch von 14,8 auf 16,7 %.

Preferential Attachment erreicht nur 4,8 %. Viele Kontakte entstehen durch wenige grosse Meisterschaften (Kapitel 6), daraus folgt nicht, wen ein Athlet als Nächstes trifft. Überraschend schwach ist auch die Faustregel Jahrgang mit 3,8 %, obwohl der Jahrgang in Kapitel 8 das stärkste Merkmal war. Gleichaltrige Paare gibt es aber sehr viele. Von den 340 638 gleich alten Kandidatenpaaren begegnen sich nur 3,8 % im Testzeitraum, kaum mehr als über alle Kandidaten. Eine hohe Assortativität bedeutet also nicht, dass sich ein Merkmal gut zur Vorhersage eignet.

Abbildung 9.2 zeigt zwei Robustheitsprüfungen. Verlangen wir für eine neue Kante mindestens zwei gemeinsame Testtage, bleiben 32 636 neue Kanten, und die Nationsregeln liegen noch deutlicher vorne. Wiederholte neue Begegnungen sind also noch stärker national. Bestimmen wir den Kern nur über den Trainingszeitraum, umfasst er 5 594 Athleten. Darunter sind auch Athleten, die später nicht mehr erfasst sind. Die Trefferquote des Zufalls sinkt deshalb von 2,7 auf 0,8 %, und mit ihr die Precision@K aller Verfahren. In beiden Prüfungen bleiben die Nationsregeln klar vorne, gefolgt von Soundarajan-Hopcroft.

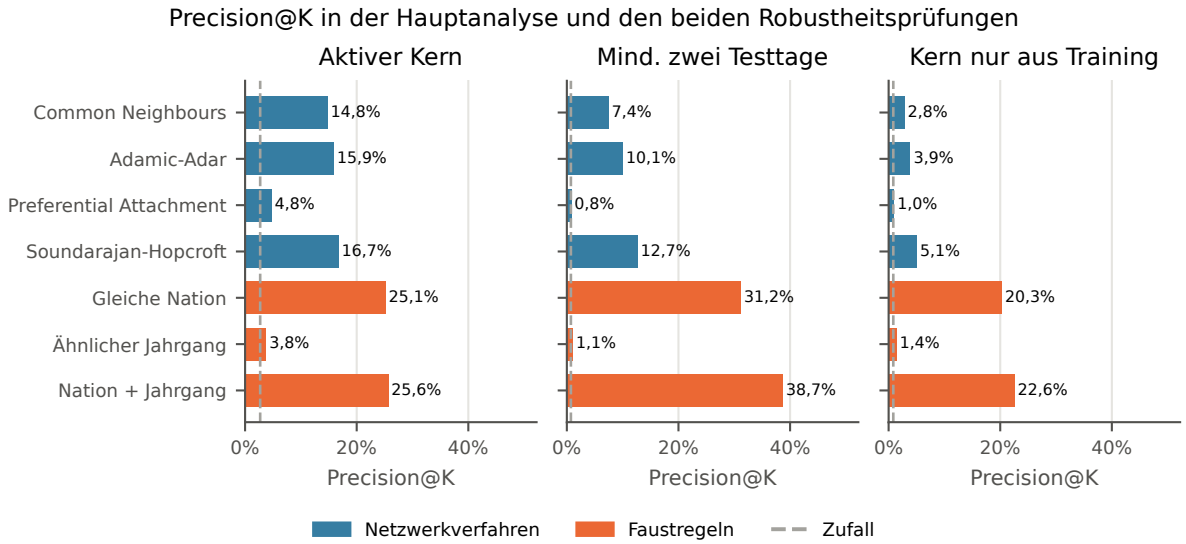


Abbildung 9.2: Precision@K je Verfahren im aktiven Kern, bei mindestens zwei gemeinsamen Testtagen und bei einem nur über das Training bestimmten Kern. Blau Netzwerkverfahren, orange Faustregeln, die gestrichelte Linie zeigt die Trefferquote einer zufälligen Auswahl im jeweiligen Szenario. Eigene Auswertung.

10 Fazit und Ausblick

10.1 Beantwortung der Fragestellungen

Nationale Prägung und Gruppen. Das Netz ist stark national geprägt. 43,1 % der Kanten im Arbeitsnetz verbinden Landsleute, bei zufällig verbundenen Athleten wären es 1,2 %. Louvain findet eine ausgeprägte Community-Struktur mit zwei Typen. Elf grosse Communities bestehen fast nur aus einer Nation. Vier grosse internationale Communities trennen sich nach Generationen und bilden sich um die Meisterschaften ihrer Zeit, von den Europameisterschaften der frühen 2000er-Jahre bis zu den aktuellen Weltmeisterschaften.

Zentrale Athleten und Teams. Ein hoher Degree entsteht bei uns durch wenige, sehr grosse internationale Veranstaltungen und nicht durch viele Wettkämpfe. Hohe Betweenness kennzeichnet Athleten an den Übergängen zwischen Generationen oder zwischen nationaler und internationaler Ebene. Stärkere Schwimmer sind signifikant zentraler, der Zusammenhang ist mit ρ zwischen 0,17 und 0,36 aber schwach bis mässig. Nationalteams, deren Athleten sich vor allem mit Landsleuten treffen, erreichen weniger Athleten anderer Nationen (Spearman $-0{,}82$).

Zusammenhalt. Wiederholte Begegnungen sind kein Zufall. Das Arbeitsnetz enthält rund zehnmal so viele wiederholte Begegnungen wie das bipartite Configuration Model. Zusammengehalten wird es von internationalen Meisterschaften. Fehlen die internationalsten Veranstaltungstage mit 30 % der Teilnahmen, bleiben nur 53,7 % der Athleten in der Giant Component, bei zufälligen Tagen 91,1 %. Das Entfernen der zentralsten Athleten verändert das Netz dagegen kaum.

Bevorzugte Verbindungen. Am stärksten verbinden sich Gleichaltrige ($r = 0{,}85$), danach Landsleute ($r = 0{,}42$). Starke Schwimmer treffen sich vor allem international untereinander, in der jüngsten Generation am deutlichsten. National treffen sich dagegen Gleichaltrige unabhängig von ihrem Niveau.

Vorhersage. Netzwerkverfahren sagen neue Begegnungen fünf- bis sechsmal besser voraus als der Zufall. Die einfache Regel gleiche Nation ist aber noch besser. Unter den aktiven Athleten

trifft sich mehr als die Hälfte der Landsleute, die sich im Trainingszeitraum nicht begegnet sind, im Testzeitraum.

Zusammen ergibt sich ein Netz mit zwei Ebenen. National entsteht ein dichtes, wiederkehrendes Netz unter Gleichaltrigen. International verbinden wenige grosse Meisterschaften die Nationen und Generationen, und dort treffen sich die stärksten Schwimmer.

10.2 Grenzen, Ausblick und Reflexion

Die Ergebnisse beruhen auf den persönlichen Bestleistungen der TOP100-Listen mit Stand 2025. Pro Disziplin ist nur die schnellste Zeit der Karriere gespeichert. Verbessert ein Athlet sie, verschwindet der frühere Tag aus den Daten. Ältere Jahre sind auch deshalb dünner erfasst, besonders vor 2005. Eine Kante zeigt einen gemeinsamen Bestleistungstag und keine persönliche Beziehung, und viele tatsächliche Begegnungen an Wettkämpfen fehlen. Zudem betreffen die 126 fehlenden Profile fast nur Frauen, und die Profilnation entspricht dem Stand 2025.

Für eine Weiterführung sehen wir mehrere Ansätze.

- **Vollständige Ergebnislisten** statt Bestleistungen würden ein echtes Begegnungsnetz liefern. Eine Kante könnte dann auch ein gemeinsames Rennen oder Finale bedeuten.
- **Zeitliche Netze pro Saison** würden zeigen, wie sich Generationen bilden, wie Karrieren verlaufen und wie stark die Pandemie 2020 das Netz verändert hat.
- **Netzwerk und Attribute kombiniert** könnten die Link Prediction verbessern, etwa Soundarajan-Hopcroft mit Nationen statt Louvain-Communities.
- **Vereine als weitere Relation** würden Trainingsgruppen sichtbar machen, sobald die Vereinsangaben vollständiger sind.
- **Diffusion** könnte untersuchen, wie sich Neuerungen wie die Hightech-Anzüge von 2008 und 2009 über gemeinsame Wettkämpfe ausbreiten. **Graphlets** könnten die Struktur nationaler Netze vergleichen.

Gut funktioniert hat, die Analysen aufeinander aufzubauen. Befunde wie der Kern um die Weltmeisterschaft 2009 oder die nationale Prägung tauchten in mehreren Kapiteln wieder auf und liessen sich so gegenseitig prüfen.

Anders machen würden wir vor allem die Datengrundlage. Wir haben einen bestehenden Datensatz aus einem früheren Projekt übernommen, der pro Disziplin nur die schnellste Zeit der Karriere enthält. Das Netz bildet deshalb gemeinsame Bestleistungstage ab und nicht alle Begegnungen an Wettkämpfen. Fehlende Profile liessen sich zudem nicht mehr nachladen, da Cloudflare den Zugriff blockierte. Mit einer eigenen, auf die Fragestellung ausgerichteten Erhebung würden wir vollständige Ergebnislisten der Wettkämpfe sammeln.

Methodisch haben wir vor allem aus der Projektion gelernt. Jeder Veranstaltungstag erzeugt eine Clique, weshalb Masse wie Clustering, k-Core oder ein Vergleich mit dem gewöhnlichen Configuration Model einen passenden Bezugspunkt brauchen. Das bipartite Configuration Model würden wir früher einsetzen, auch für den Modularity-Test in Kapitel 5. Kapitel 8 hat zudem gezeigt, wie leicht zusammengefasste Gruppen einen Effekt vortäuschen. Ergebnisse auf Teilgruppen zu prüfen, würden wir von Anfang an einplanen.

Literaturverzeichnis

Henninger, M. (2024, November). *Soziale Netzwerkanalyse* (Vorlesungsskript). Fachhochschule Nordwestschweiz.

Liben-Nowell, D., & Kleinberg, J. (2007). The link-prediction problem for social networks. *Journal of the American Society for Information Science and Technology*, *58*(7), 1019–1031. https://doi.org/10.1002/asi.20591

Newman, M. E. J., Strogatz, S. H., & Watts, D. J. (2001). Random graphs with arbitrary degree distributions and their applications. *Physical Review E*, *64*(2), 026118. https://doi.org/10.1103/PhysRevE.64.026118

swimrankings.net. (2025). *Ranglisten und Athletenprofile*. https://www.swimrankings.net

A Übersicht über Code und Daten

Tabelle A.1 zeigt, wo die Umsetzung und die Ergebnisse jedes Kapitels zu finden sind. Alle Pfade beziehen sich auf das Projektverzeichnis. Die Abbildungen des Reports exportieren die Notebooks nach Report/graphics, die beiden Gephi-Abbildungen entstehen aus data/processed/networks/Athletes.gephi.

Tabelle A.1: Kapitel mit zugehörigem Code und gespeicherten Ergebnissen.

Kapitel	Code	Ergebnisse
1 Einleitung	Notebooks/00_projekt.ipynb	–
2 Daten	scraper/scripts/scrape.py	data/raw/athlete_data_master.csv
	Notebooks/01_eda.ipynb	data/processed/athlete_data_clean.parquet
3 Modellierung	Notebooks/02_modellierung.ipynb	data/processed/networks
4 Reduktion	Notebooks/03_reduktion.ipynb	data/processed/networks/nations.gexf
5 Communities	Notebooks/04_communities.ipynb	data/processed/networks/athlete_communities.parquet
6 Zentralität	Notebooks/05_zentralitaet.ipynb	data/processed/centrality
	Notebooks/centrality_utils.py	
7 Zusammenhalt	Notebooks/06_zusammenhalt.ipynb	data/processed/zusammenhalt
8 Assortativität	Notebooks/07_assortativitaet.ipynb	data/processed/assortativitaet
9 Link Prediction	Notebooks/08_link_prediction.ipynb	data/processed/link_prediction
	Notebooks/link_prediction_utils.py	
10 Fazit	Notebooks/09_fazit.ipynb	–

B Hilfsmittelverzeichnis

Verwendete Werkzeuge und KI Unterstützung mit Zweck, betroffenen Arbeitsschritten und den zugehörigen Prompts dokumentieren.